

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



NGHIÊN CỨU KHOA HỌC

**HỌC TĂNG CƯỜNG ĐA TÁC TỬ CHO MẠNG
UAV-IOT HỖ TRỢ CHỐNG GÂY NHIỀU VỚI
TRUYỀN THÔNG BACKSCATTER ỨNG DỤNG
RF-POWERED**

Giảng viên hướng dẫn: TS.Nguyễn Ngọc Tân

Sinh viên thực hiện: Trần Khánh Duy – 22025520
Hoàng Ngọc Nhi – 23020130

Hà Nội – Tháng 6 năm 2026

Mục lục

Mục lục.	i
Danh mục hình ảnh .	iii
Danh mục bảng .	iv
Tóm tắt.	v
1 Giới thiệu .	1
1.1 Bối cảnh nghiên cứu .	1
1.2 Vấn đề gây nhiễu trong mạng UAV-IoT .	1
1.3 Động lực sử dụng học tăng cường đa tác tử .	1
1.4 Khoảng trống nghiên cứu .	2
1.5 Mục tiêu nghiên cứu .	2
1.6 Phạm vi nghiên cứu .	3
1.7 Đóng góp chính .	3
1.8 Cấu trúc báo cáo .	3
2 Cơ sở lý thuyết và nghiên cứu liên quan .	4
2.1 Mạng UAV-IoT .	4
2.2 Gây nhiễu và chống nhiễu trong mạng không dây .	4
2.3 Truyền thông RF-powered và backscatter-inspired .	4
2.4 MDP và học tăng cường .	4
2.5 DQN và Double DQN .	5
2.6 Học tăng cường phân cấp và trừu tượng hóa hành động .	5
2.7 Học tăng cường đa tác tử .	5
2.8 QMIX .	6
2.9 Tổng quan nghiên cứu liên quan và khoảng trống .	6

3	Mô hình hệ thống và phát biểu bài toán	7
3.1	Tổng quan hệ thống	7
3.2	Ký hiệu chính	8
3.3	Mô hình di chuyển và hàng đợi	8
3.4	Mô hình kênh và gây nhiễu	9
3.5	Năng lượng và truyền thông backscatter-inspired	9
3.6	Trạng thái, hành động và phần thưởng	10
3.7	Mục tiêu tối ưu và chỉ số đánh giá	10
4	Phương pháp đề xuất	11
4.1	Tổng quan quy trình	11
4.2	Flat DDQN baseline	11
4.3	Trừu tượng hóa hành động phân cấp	12
4.4	Hierarchical DDQN	12
4.5	QMIX-Hierarchical	13
4.6	Huấn luyện và thực thi	13
4.7	Pseudocode tóm tắt	14
4.8	Tóm tắt phương pháp	14
5	Thực nghiệm, kết quả và thảo luận	15
5.1	Thiết lập thực nghiệm	15
5.2	So sánh tổng thể trong Scenario 4	16
5.3	Tiến trình thuật toán	17
5.4	Ổn định đa seed của QMIX	18
5.5	Thử nghiệm đánh giá thành phần (ablation study) về tính công bằng	19
5.6	Thảo luận	21
5.7	Kết luận	22
5.8	Hướng phát triển	22
	Tài liệu tham khảo	23

Danh mục hình ảnh

3.1	Mô hình Scenario 4: hai UAV phục vụ mười lăm thiết bị IoT di thể dưới tác động của một jammer di động. Backscatter được mô tả ở mức trừu tượng hệ thống thông qua trạng thái primary busy và hệ số công suất hiệu dụng.	7
3.2	Luồng hoạt động theo frame: quan sát trạng thái, chọn hành động mức cao, executor ánh xạ sang hành động nguyên thủy, môi trường cập nhật và trả về reward/metrics.	8
4.1	Giao diện hành động phân cấp. Tác tử học chọn một trong 10 hành động mức cao; executor dựa trên quy tắc chuyển hành động này thành bộ ba nguyên thủy gồm di chuyển, IoT mục tiêu và chế độ truyền thông.	11
4.2	QMIX-Hierarchical. Trong huấn luyện, mixer sử dụng trạng thái toàn cục và phần thưởng chung để học Q_{tot} . Trong đánh giá, mỗi UAV chọn hành động mức cao từ quan sát cục bộ, sau đó executor chuyển sang hành động nguyên thủy.	13
5.1	Throughput/frame của các baseline và phương pháp học trong Scenario 4. Khoảng cách lớn giữa Flat DDQN và các phương pháp phân cấp cho thấy vai trò của trừu tượng hóa hành động.	16
5.2	So sánh packet drop, jamming failure và fairness. QMIX base giảm jamming failure và cải thiện fairness so với kết quả Hierarchical DDQN đơn chạy trong gói artifact hiện có.	17
5.3	Tiến trình kết quả: Flat DDQN cho thấy nút thắt không gian hành động; Hierarchical DDQN chứng minh hiệu quả trừu tượng hóa hành động; QMIX thêm phối hợp đa tác tử.	18
5.4	Mean/std của QMIX base trên ba seed. Throughput ổn định hơn so với các chỉ số phối hợp như jamming failure và fairness.	19
5.5	Đánh đổi throughput–fairness trong các biến thể. fair_w2 có throughput và jamming tốt hơn nhưng fairness trung bình thấp hơn QMIX base.	20
5.6	Thử nghiệm đánh giá thành phần về tính công bằng theo nhóm chỉ số. Vô hiệu hóa hành động cân bằng làm giảm throughput/fairness và tăng jamming so với QMIX base.	21

Danh mục bảng

2.1	Vai trò của các nền tảng lý thuyết trong đề tài.	6
3.1	Ký hiệu chính trong mô hình hệ thống.	8
4.1	Mười hành động mức cao trong executor phân cấp.	12
5.1	Thiết lập mô phỏng chính được dùng trong báo cáo.	15
5.2	Các chỉ số đánh giá chính. Dấu $\uparrow$ nghĩa là càng cao càng tốt; dấu $\downarrow$ nghĩa là càng thấp càng tốt.	15
5.3	So sánh tổng thể trong Scenario 4. Bảng chỉ giữ các chỉ số chính để dễ đọc. . .	16
5.4	Tiến trình thuật toán từ hành động phẳng đến hành động phân cấp và QMIX. . .	17
5.5	Kết quả QMIX base theo seed và thống kê mean/std.	19
5.6	Ablation công bằng. QMIX base được giữ làm thiết lập cuối cùng vì trade-off tổng thể tốt nhất trong các biến thể đã kiểm tra.	20

Tóm tắt

Mạng IoT hỗ trợ bởi thiết bị bay không người lái (UAV) là một hướng tiếp cận linh hoạt cho thu thập dữ liệu trong khu vực thiếu hạ tầng hoặc có thiết bị năng lượng hạn chế. Khi xuất hiện jammer di động, UAV phải đồng thời quyết định vị trí, thiết bị cần phục vụ và chế độ truyền thông trong điều kiện kênh thay đổi, hàng đợi biến động và rủi ro gây nhiễu. Bài toán càng phức tạp hơn khi hệ thống cho phép thiết bị IoT hoạt động theo các chế độ nghỉ (idle), thu năng lượng (harvest), backscatter ứng dụng RF-powered và truyền chủ động (active transmission).

Báo cáo này nghiên cứu bài toán điều khiển UAV-IoT chống gây nhiễu bằng học tăng cường sâu và học tăng cường đa tác tử. Thiết lập đánh giá cuối cùng bám theo cấu hình đã triển khai trong dự án: 2 UAV, 15 thiết bị IoT dị thể, 1 jammer di động, frame length bằng 10 và episode length bằng 200. Trong cấu hình này, giao diện hành động nguyên thủy có 864 hành động, gây khó khăn cho Flat DDQN. Để giảm độ phức tạp, báo cáo sử dụng giao diện hành động phân cấp gồm 10 hành động mức cao; một executor dựa trên quy tắc ánh xạ hành động mức cao về bộ ba hành động nguyên thủy gồm di chuyển, IoT mục tiêu và chế độ truyền.

Kết quả hiện có cho thấy Flat DDQN gặp khó khăn với giao diện 864 hành động, trong khi Hierarchical DDQN chứng minh rằng trừu tượng hóa hành động giúp bài toán khả học hơn. Phương pháp chính được lựa chọn là QMIX-Hierarchical, trong đó mỗi UAV chọn hành động mức cao từ quan sát cục bộ, còn mạng trộn QMIX sử dụng trạng thái toàn cục và phần thưởng chung trong huấn luyện. QMIX-Hierarchical cho thấy hiệu quả ổn định hơn qua ba seed và có xu hướng cải thiện các chỉ số gây nhiễu/công bằng so với kết quả Hierarchical DDQN đơn chạy trong gói thực nghiệm hiện có. Báo cáo diễn giải kết quả một cách thận trọng: QMIX không được khẳng định vượt Hierarchical DDQN về thông lượng trung bình, tính công bằng chưa được giải quyết triệt để, và mô hình backscatter là trừu tượng mức hệ thống chứ không phải xác thực vật lý đầy đủ.

Chapter 1: Giới thiệu

1.1. Bối cảnh nghiên cứu

Internet vạn vật (Internet of Things, IoT) ngày càng được triển khai trong môi trường phân tán, khó tiếp cận hoặc thiếu hạ tầng truyền thông cố định. Trong các bối cảnh này, thiết bị bay không người lái (Unmanned Aerial Vehicle, UAV) có thể đóng vai trò như nút thu thập dữ liệu, trạm phủ sóng tạm thời hoặc nền tảng phục vụ linh hoạt cho các thiết bị IoT [4]. Khả năng di chuyển giúp UAV thích nghi với phân bố thiết bị, trạng thái hàng đợi và chất lượng kênh theo thời gian.

Nhiều thiết bị IoT có năng lượng hạn chế nên không thể phụ thuộc hoàn toàn vào truyền chủ động công suất cao. RF-powered communication và ambient backscatter cung cấp một hướng tiếp cận tiết kiệm năng lượng: thiết bị có thể thu năng lượng từ tín hiệu RF, phản xạ tín hiệu sẵn có để truyền dữ liệu, hoặc truyền chủ động khi đủ năng lượng [1, 2]. Trong báo cáo này, backscatter được dùng như một *trình tượng mức hệ thống*, không phải mô hình vật lý ambient-backscatter đầy đủ.

1.2. Vấn đề gây nhiễu trong mạng UAV-IoT

Gây nhiễu vô tuyến làm tăng nhiễu tại bộ thu, suy giảm SINR và làm tăng xác suất truyền thất bại [10]. Với UAV-IoT, tác động của jammer không chỉ làm giảm thông lượng mà còn làm tăng tỉ lệ mất mát gói tin (packet drop), kéo dài hàng đợi và làm giảm tính công bằng phục vụ giữa các thiết bị. Khi jammer di động, vùng rủi ro nhiễu thay đổi theo thời gian; UAV phải cân bằng giữa di chuyển đến gần IoT, tránh jammer và chọn chế độ truyền phù hợp.

Tại mỗi frame, UAV cần ra quyết định tổ hợp: hướng di chuyển, IoT mục tiêu và chế độ truyền thông. Các heuristic đơn giản có thể hiệu quả trong một số điều kiện nhưng thường chỉ tối ưu một khía cạnh như khoảng cách, SINR, active-only hoặc backscatter-only. Do đó, bài toán cần một chính sách thích nghi với trạng thái mạng.

1.3. Động lực sử dụng học tăng cường đa tác tử

Học tăng cường (Reinforcement Learning, RL) phù hợp với điều khiển mạng động vì chính sách có thể học từ tương tác với môi trường và tối ưu phần thưởng dài hạn [6]. DQN và Double DQN mở rộng Q-learning bằng mạng nơ-ron sâu, giúp xử lý không gian trạng thái lớn và hành động rời rạc [3, 9].

Tuy nhiên, trong hệ nhiều UAV, mỗi UAV có quan sát và hành động riêng nhưng mục tiêu

là hiệu quả toàn mạng. Vì vậy, học tăng cường đa tác tử (Multi-Agent Reinforcement Learning, MaDRL) phù hợp hơn cách điều khiển đơn tác tử. QMIX là một lựa chọn tự nhiên cho bài toán hợp tác có hành động rời rạc, phần thưởng chung, quan sát cục bộ và trạng thái toàn cục dùng trong huấn luyện [5].

1.4. Khoảng trống nghiên cứu

Các nghiên cứu RF-powered/backscatter thường tập trung vào lập lịch, offloading hoặc tối ưu chế độ truyền trong các thiết lập riêng lẻ [1, 2, 8]. Các nghiên cứu UAV-IoT lại thường nhấn mạnh quỹ đạo, vùng phủ hoặc thu thập dữ liệu. Khoảng trống của đề tài là sự kết hợp đồng thời:

- Nhiều UAV phục vụ IoT dị thể;
- jammer di động làm thay đổi vùng rủi ro nhiễu;
- Lựa chọn harvest/backscatter/active ở mức hệ thống;
- Giao diện hành động phân cấp để giảm độ khó học;
- QMIX-Hierarchical để học phối hợp nhiều UAV.

Vấn đề trung tâm không chỉ là chọn thuật toán, mà là thiết kế lại giao diện điều khiển để biến bài toán có không gian hành động lớn thành bài toán học được.

1.5. Mục tiêu nghiên cứu

Báo cáo hướng đến các mục tiêu:

1. Mô hình hóa môi trường UAV-IoT có jammer di động, hàng đợi IoT, năng lượng thiết bị và các chế độ idle/harvest/backscatter/active;
2. Xây dựng mô hình trừu tượng lấy cảm hứng từ backscatter và RF-powered để mô tả quyết định truyền thông của mạng IoT năng lượng thấp.;
3. Đánh giá Flat DDQN, Hierarchical DDQN và QMIX-Hierarchical trên cùng cấu hình Scenario 4 đã triển khai;
4. Phân tích thông lượng, tỉ lệ mất mát gói tin, tác động của nhiễu, tính công bằng và hiệu quả sử dụng năng lượng;
5. Kiểm tra vai trò của hành động `BALANCE_UNDESERVED_IOT` trong hành vi phối hợp.

1.6. Phạm vi nghiên cứu

Nguồn sự thật của báo cáo là cấu hình đã triển khai và đánh giá: 2 UAV, 15 thiết bị IoT, 1 jammer di động, frame length 10 và episode length 200. Trong cấu hình này, giao diện hành động nguyên thủy có 864 hành động, giao diện phân cấp có 10 hành động mức cao, quan sát cục bộ QMIX có kích thước 97 và trạng thái toàn cục có kích thước 70.

Báo cáo không thay đổi tham số mô phỏng, không huấn luyện lại mô hình và không tạo kết quả mới. Các bảng tham số từng được đề xuất trong giai đoạn lập kế hoạch, nếu khác cấu hình trên, chỉ được xem là tài liệu tham khảo nội bộ.

1.7. Đóng góp chính

Các đóng góp được diễn giải thận trọng như sau:

- Đóng góp 1.** Phát biểu bài toán UAV-IoT dưới jammer di động như bài toán điều khiển học tăng cường hợp tác.
- Đóng góp 2.** Xây dựng giao diện hành động phân cấp giảm hành động trực tiếp từ 864 xuống 10 trong Scenario 4.
- Đóng góp 3.** Đánh giá Hierarchical DDQN để chứng minh vai trò của trừu tượng hóa hành động.
- Đóng góp 4.** Triển khai và đánh giá QMIX-Hierarchical cho phối hợp nhiều UAV với quan sát cục bộ, phần thưởng chung và mixer dùng trạng thái toàn cục.
- Đóng góp 5.** Phân tích thông lượng, nhiễu, tính công bằng và nghiên cứu loại bỏ thành phần của cơ chế cân bằng thiết bị chưa được phục vụ đầy đủ.

QMIX-Hierarchical được chọn làm phương pháp MaDRL chính vì duy trì thông lượng tương đương Hierarchical DDQN, đồng thời có bằng chứng nhiều lần chạy ngẫu nhiên về độ ổn định và cải thiện các hành vi hợp tác liên quan đến thất bại do gây nhiễu và tính công bằng.

1.8. Cấu trúc báo cáo

Chương 2 trình bày cơ sở lý thuyết và nghiên cứu liên quan. Chương 3 mô tả mô hình hệ thống và phát biểu bài toán. Chương 4 trình bày giao diện hành động phân cấp và phương pháp QMIX-Hierarchical. Chương 5 trình bày thiết lập thực nghiệm, kết quả, thảo luận, kết luận và hướng phát triển.

Chapter 2: Cơ sở lý thuyết và nghiên cứu liên quan

2.1. Mạng UAV-IoT

Mạng UAV-IoT là hệ thống trong đó UAV hỗ trợ thiết bị IoT thông qua thu thập dữ liệu, chuyển tiếp, mở rộng vùng phủ hoặc cung cấp kết nối tạm thời. So với hạ tầng cố định, UAV có tính cơ động cao và có thể thay đổi vị trí theo nhu cầu phục vụ [4]. Khi nhiều UAV cùng hoạt động, quyết định của một UAV ảnh hưởng đến UAV khác thông qua vùng phủ, trùng mục tiêu, nhiễu và phân bổ tải. Do đó, bài toán có bản chất điều khiển đa tác tử.

2.2. Gây nhiễu và chống nhiễu trong mạng không dây

Gây nhiễu là quá trình phát tín hiệu không mong muốn nhằm làm giảm chất lượng liên kết không dây. Ở mức khái niệm, ảnh hưởng của jammer lên liên kết có thể biểu diễn qua:

$$\text{SINR} = \frac{P_s}{N_0 + I_{\text{jam}}}, \quad (2.1)$$

trong đó P_s là công suất tín hiệu mong muốn, N_0 là nhiễu nền và I_{jam} là nhiễu do jammer. Khi jammer di động, I_{jam} thay đổi theo vị trí UAV, IoT và jammer, khiến việc chọn vị trí và chế độ truyền trở thành bài toán thích nghi.

2.3. Truyền thông RF-powered và backscatter-inspired

RF-powered communication cho phép thiết bị năng lượng thấp tận dụng năng lượng vô tuyến để hỗ trợ hoạt động truyền thông. Ambient backscatter cho phép thiết bị điều chế thông tin bằng cách phản xạ tín hiệu RF sẵn có, qua đó giảm nhu cầu phát sóng chủ động [2]. Trong bối cảnh MEC/offloading và RF-powered backscatter, DRL đã được dùng để học lập lịch hoặc lựa chọn chế độ truyền trong môi trường động [1, 8].

Trong dự án này, backscatter được mô hình hóa như một trường tượng ở mức hệ thống: trạng thái primary busy, loại thiết bị, hàng đợi, năng lượng và hệ số công suất backscatter hiệu dụng quyết định khả năng truyền. Cách mô tả này phù hợp cho nghiên cứu điều khiển mạng nhưng không phải xác thực vật lý đầy đủ của ambient backscatter.

2.4. MDP và học tăng cường

Một tiến trình quyết định Markov được mô tả bởi:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma), \quad (2.2)$$

trong đó $\mathcal{S}$ là không gian trạng thái, $\mathcal{A}$ là không gian hành động, P là xác suất chuyển trạng thái, R là hàm thưởng và γ là hệ số chiết khấu. Mục tiêu của RL là học chính sách $\pi(a|s)$ tối đa hóa return kỳ vọng:

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \quad (2.3)$$

Trong UAV-IoT, trạng thái bao gồm vị trí, hàng đợi, năng lượng, jammer và kênh; hành động gồm di chuyển, chọn mục tiêu và chọn chế độ truyền.

2.5. DQN và Double DQN

Q-learning học hàm giá trị hành động $Q(s, a)$. DQN xấp xỉ hàm này bằng mạng nơ-ron sâu và sử dụng replay buffer cùng target network để ổn định huấn luyện [3]. Double DQN giảm thiên lệch đánh giá quá cao bằng cách dùng online network để chọn hành động và target network để đánh giá hành động đó [9]:

$$y_t^{\text{DDQN}} = r_t + \gamma Q^{-} \left(s_{t+1}, \arg \max_{a'} Q(s_{t+1}, a') \right). \quad (2.4)$$

Trong báo cáo, Flat DDQN là baseline trên giao diện hành động nguyên thủy; Hierarchical DDQN dùng cùng ý tưởng nhưng đầu ra là 10 hành động mức cao.

2.6. Học tăng cường phân cấp và trừu tượng hóa hành động

Không gian hành động tổ hợp làm cho học giá trị trở nên khó khăn. Với $N = 15$ IoT, hành động nguyên thủy trong Scenario 4 có:

$$|\mathcal{A}_{\text{flat}}| = 9(N + 1)6 = 9(15 + 1)6 = 864. \quad (2.5)$$

Action abstraction giảm độ khó bằng cách cho tác tử chọn hành động mức cao, sau đó executor chuyển hành động này thành hành động nguyên thủy [7]. Trong triển khai hiện tại, executor là rule-based và dùng thông tin môi trường để chọn mục tiêu, chế độ và hướng di chuyển.

2.7. Học tăng cường đa tác tử

Trong MaDRL, nhiều tác tử cùng tương tác với môi trường. Với hệ nhiều UAV, mỗi UAV có quan sát cục bộ nhưng phần thưởng là mục tiêu chung của toàn mạng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{T-1} \gamma^t r_t^{\text{global}} \right]. \quad (2.6)$$

Một mô hình phổ biến là centralized training with decentralized execution (CTDE). Trong báo cáo này, cần diễn đạt cẩn trọng: QMIX-Hierarchical chọn hành động mức cao dựa trên quan sát cục bộ, nhưng executor ánh xạ hành động mức cao sang hành động nguyên thủy bằng thông tin môi trường.

2.8. QMIX

QMIX là phương pháp phân rã giá trị cho bài toán hợp tác rời rạc [5]. Mỗi tác tử có hàm giá trị cục bộ $Q_u(o^u, a^u)$, và mixer kết hợp các giá trị này thành giá trị đội:

$$Q_{\text{tot}} = f_{\text{mix}}(Q_1, \dots, Q_U, s). \quad (2.7)$$

QMIX áp đặt ràng buộc đơn điệu:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_u} \geq 0, \quad \forall u \in \{1, \dots, U\}. \quad (2.8)$$

Ràng buộc này giúp việc chọn hành động cục bộ phù hợp với tối ưu hóa giá trị chung. Sau khi dùng giao diện 10 hành động mức cao, bài toán UAV-IoT phù hợp với QMIX vì có nhiều UAV hợp tác, phần thưởng chung và trạng thái toàn cục dùng trong huấn luyện.

2.9. Tổng quan nghiên cứu liên quan và khoảng trống

Bảng 2.1 tóm tắt vai trò của các lý thuyết nền trong đề tài. Khoảng trống chính không chỉ nằm ở thuật toán QMIX, mà ở cách biến bài toán điều khiển nguyên thủy lớn thành bài toán rời rạc nhỏ hơn và có ý nghĩa miền bài toán.

Table 2.1: Vai trò của các nền tảng lý thuyết trong đề tài.

Nền tảng	Vai trò trong báo cáo
UAV-IoT	Mô hình hóa nhiều UAV phục vụ các thiết bị IoT di thể trong môi trường động.
RF-powered/backscatter	Cơ sở cho abstraction idle/harvest/backscatter/active của IoT năng lượng thấp.
DDQN	Baseline học giá trị cho hành động rời rạc và đánh giá khó khăn của hành động nguyên thủy.
Hierarchical RL	Giảm giao diện điều khiển từ 864 hành động nguyên thủy xuống 10 hành động mức cao.
MaDRL/QMIX	Học phối hợp nhiều UAV bằng per-agent Q-network và mixer dùng trạng thái toàn cục.

Chapter 3: Mô hình hệ thống và phát biểu bài toán

3.1. Tổng quan hệ thống

Báo cáo xét mạng UAV-IoT hoạt động theo frame rời rạc. Tập UAV là $\mathcal{U} = \{1, \dots, U\}$, tập IoT là $\mathcal{I} = \{1, \dots, N\}$, và tập jammer là $\mathcal{J} = \{1, \dots, J\}$. Thiết lập đánh giá cuối cùng sử dụng:

$$U = 2, \quad N = 15, \quad J = 1, \quad L = 10, \quad T = 200. \quad (3.1)$$

Hình 3.1 minh họa cấu trúc Scenario 4. Tại mỗi frame, IoT sinh gói, jammer di chuyển, UAV chọn hành động, môi trường cập nhật truyền thông/năng lượng/hàng đợi và trả về phần thưởng chung.




Figure 3.1: Mô hình Scenario 4: hai UAV phục vụ mười lăm thiết bị IoT dị thể dưới tác động của một jammer di động. Backscatter được mô tả ở mức trừu tượng hệ thống thông qua trạng thái primary busy và hệ số công suất hiệu dụng.

Luồng hoạt động theo frame




Figure 3.2: Luồng hoạt động theo frame: quan sát trạng thái, chọn hành động mức cao, executor ánh xạ sang hành động nguyên thủy, môi trường cập nhật và trả về reward/metrics.

3.2. Ký hiệu chính

Bảng 3.1 tóm tắt các ký hiệu được dùng trong chương này.

Table 3.1: Ký hiệu chính trong mô hình hệ thống.

Ký hiệu	Ý nghĩa	Scenario 4
$\mathcal{U}, U$	Tập UAV và số UAV	$U = 2$
$\mathcal{I}, N$	Tập IoT và số thiết bị	$N = 15$
$\mathcal{J}, J$	Tập jammer và số jammer	$J = 1$
L, T	Độ dài frame và episode	$L = 10, T = 200$
$q_{i,t}, B_{i,t}$	Hàng đợi và năng lượng của IoT i	trạng thái mô phỏng
b_t	Trạng thái primary busy	Bernoulli theo cấu hình
o_t^u, s_t	Quan sát cục bộ và trạng thái toàn cục	$d_o = 97, d_s = 70$
a_t^u, z_t^u	Hành động nguyên thủy và hành động mức cao	864 và 10

3.3. Mô hình di chuyển và hàng đợi

UAV u có vị trí (x_t^u, y_t^u) , độ cao cố định, năng lượng E_t^u và bán kính phủ R_{cov} . Lệnh di chuyển thuộc chín hướng rời rạc. Với $\Delta = (\Delta_x, \Delta_y)$, cập nhật vị trí được mô tả:

$$x_{t+1}^u = \text{clip}(x_t^u + \Delta_x v_{\max}, 0, W), \quad (3.2)$$

$$y_{t+1}^u = \text{clip}(y_t^u + \Delta_y v_{\max}, 0, H). \quad (3.3)$$

Mỗi IoT i có hàng đợi $q_{i,t}$, dung lượng $Q_i^{\max}$, năng lượng $B_{i,t}$ và loại $c_i \in \{1, 2, 3\}$. Số gói đến trong frame được mô tả:

$$A_{i,t} \sim \text{Binomial}(L, p_i^{\text{arr}}). \quad (3.4)$$

Cập nhật hàng đợi ở mức báo cáo:

$$q_{i,t+1} = \min(Q_i^{\max}, [q_{i,t} - D_{i,t}]^+ + A_{i,t}), \quad (3.5)$$

trong đó $D_{i,t}$ là số gói được phục vụ thành công. Phần vượt quá dung lượng được tính vào tỉ lệ mất mát gói tin.

3.4. Mô hình kênh và gây nhiễu

Suy hao đường truyền và công suất nhận được viết:

$$L(d) = \max(d, 1)^\alpha, \quad (3.6)$$

$$P_{\text{rx}}(P, d) = \frac{P}{L(d)}. \quad (3.7)$$

Nhiều từ jammer j tại bộ thu r được tính khi bộ thu nằm trong bán kính ảnh hưởng:

$$I_{j,r} = \begin{cases} \frac{P_j}{\max(d_{j,r}, 1)^\alpha}, & d_{j,r}^{2D} \leq R_j, \\ 0, & \text{ngược lại.} \end{cases} \quad (3.8)$$

SINR của liên kết từ nguồn a đến bộ thu r :

$$\Gamma_{a,r,t} = \frac{P_{\text{rx}}(P_a, d_{a,r})}{N_0 + \sum_{j \in \mathcal{J}} I_{j,r}}. \quad (3.9)$$

Xác suất truyền thành công được mô phỏng bằng một hàm tăng theo SINR:

$$p_{\text{succ}}(\Gamma) = \begin{cases} 1, & \theta = 0, \Gamma > 0, \\ 0, & \theta = 0, \Gamma = 0, \\ \min\left(1, \frac{\Gamma}{\Gamma + \theta}\right), & \Gamma \geq \theta, \\ 0.1 \frac{\Gamma}{\theta}, & 0 \leq \Gamma < \theta. \end{cases} \quad (3.10)$$

Một thất bại được xem là liên quan đến gây nhiễu khi SINR thấp hơn ngưỡng và nhiễu jammer lớn hơn nhiễu nền.

3.5. Năng lượng và truyền thông backscatter-inspired

Môi trường hỗ trợ idle, harvest, backscatter, active, relay và avoid-jammer; báo cáo tập trung vào idle/harvest/backscatter/active/avoid-jammer. Harvest cập nhật năng lượng IoT:

$$B_{i,t+1} = \min(B_i^{\max}, B_{i,t} + h_i). \quad (3.11)$$

Active transmission yêu cầu $B_{i,t} \geq c_i^{\text{act}}$ và làm giảm năng lượng:

$$B_{i,t+1} = B_{i,t} - c_i^{\text{act}}. \quad (3.12)$$

Backscatter được mô phỏng bằng công suất hiệu dụng phụ thuộc nguồn RF và hệ số backscatter của thiết bị. Đây là trừ tượng ở mức hệ thống, chưa xác thực đầy đủ đặc tính vật lý ambient backscatter.

3.6. Trạng thái, hành động và phần thưởng

Quan sát cục bộ của UAV gồm trạng thái UAV, jammer gần nhất, primary busy và đặc trưng tương đối của từng IoT. Kích thước trong Scenario 4:

$$d_o = 7 + 6N = 7 + 6 \cdot 15 = 97. \quad (3.13)$$

Trạng thái toàn cục:

$$d_s = 3U + 4N + 2J + 2 = 3 \cdot 2 + 4 \cdot 15 + 2 \cdot 1 + 2 = 70. \quad (3.14)$$

Không gian hành động phẳng và phân cấp:

$$|\mathcal{A}_{\text{flat}}| = 864, \quad |\mathcal{A}_{\text{hier}}| = 10. \quad (3.15)$$

Phần thưởng chung của môi trường:

$$r_t = w_{\text{thr}}S_t + w_{\text{avoid}}A_t - w_{\text{drop}}D_t - w_{\text{delay}}\bar{q}_t - w_{\text{uavE}}E_t^u - w_{\text{jam}}J_t - w_{\text{col}}C_t - w_{\text{unfair}}(1 - F_t), \quad (3.16)$$

trong đó S_t là số gói thành công, D_t là số gói tin mất mát, J_t là thất bại do nhiễu, C_t là va chạm và F_t là chỉ số công bằng Jain.

3.7. Mục tiêu tối ưu và chỉ số đánh giá

Mục tiêu RL ở mức báo cáo:

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \quad (3.17)$$

Các chỉ số đánh giá chính:

$$\eta = \frac{\sum_{i \in \mathcal{I}} D_i}{T_{\text{ep}}}, \quad \rho_{\text{drop}} = \frac{\sum_i \text{Dropped}_i}{\max(\sum_i \text{Arrived}_i, 1)}, \quad (3.18)$$

$$\rho_{\text{jam}} = \frac{\text{jamming failures}}{\max(\text{transmission attempts}, 1)}, \quad F = \frac{(\sum_i D_i)^2}{N \sum_i D_i^2 + \epsilon}, \quad (3.19)$$

$$\xi = \frac{\sum_i D_i}{\max(E_{\text{UAV}} + E_{\text{IoT}}, 10^{-9})}. \quad (3.20)$$

Bài toán cuối cùng là học chính sách UAV hợp tác nhằm tăng thông lượng, giảm tỉ lệ mất mát gói tin, hạn chế thất bại do gây nhiễu và duy trì tính công bằng trong phạm vi mô phỏng đã triển khai.

Chapter 4: Phương pháp đề xuất

4.1. Tổng quan quy trình

Phương pháp được xây dựng theo ba bước: Flat DDQN kiểm tra khả năng học trực tiếp trên hành động nguyên thủy; Hierarchical DDQN đánh giá tác dụng của giao diện hành động mức cao; QMIX-Hierarchical dùng cùng giao diện 10 hành động để học phối hợp nhiều UAV.

Trọng tâm của phương pháp là giảm độ khó học bằng trừu tượng hóa hành động. Trong Scenario 4, hành động nguyên thủy có 864 tổ hợp, còn hành động phân cấp có 10 lựa chọn mức cao. Hình 4.1 tóm tắt quy trình này.




Figure 4.1: Giao diện hành động phân cấp. Tác tử học chọn một trong 10 hành động mức cao; executor dựa trên quy tắc chuyển hành động này thành bộ ba nguyên thủy gồm di chuyển, IoT mục tiêu và chế độ truyền thông.

4.2. Flat DDQN baseline

Hành động nguyên thủy của UAV u là:

$$a_t^u = (m_t^u, i_t^u, c_t^u), \quad (4.1)$$

trong đó m_t^u là lệnh di chuyển, i_t^u là IoT mục tiêu và c_t^u là chế độ truyền thông. Với 15 IoT, số hành động là 864. DDQN dùng mục tiêu Double-DQN:

$$y_t = r_t + \gamma(1 - d_t)Q^- \left(s_{t+1}, \arg \max_{a'} Q(s_{t+1}, a') \right). \quad (4.2)$$

Flat DDQN giữ nguyên ngữ nghĩa hành động của mô phỏng nên là baseline cần thiết. Tuy nhiên, nhiều hành động phẳng không hợp lệ hoặc ít giá trị trong từng trạng thái, làm exploration và credit assignment kém hiệu quả.

4.3. Trừu tượng hóa hành động phân cấp

Thay vì chọn a_t^u , UAV chọn hành động mức cao:

$$z_t^u \in \mathcal{Z}, \quad |\mathcal{Z}| = 10. \quad (4.3)$$

Bảng 4.1 liệt kê mười hành động mức cao được dùng trong executor.

Table 4.1: Mười hành động mức cao trong executor phân cấp.

ID	Hành động	Hành vi chính
0	IDLE_SAFE	Nghỉ hoặc chỉ truyền khi cơ hội đủ an toàn.
1	SERVE_NEAREST_QUEUE	Phục vụ IoT gần nhất có hàng đợi.
2	SERVE_BEST_SINR	Ưu tiên IoT có SINR tốt.
3	PRIORITIZE_BACKSCATTER_TYPE23	Ưu tiên Type 2/3 và backscatter.
4	PRIORITIZE_ACTIVE_TYPE1	Ưu tiên Type 1 và active.
5	HARVEST_LOW_ENERGY	Hỗ trợ thiết bị năng lượng thấp và harvest.
6	AVOID_JAMMER	Tránh jammer và giảm rủi ro nhiễu.
7	BALANCE_UNDESERVED_IOT	Ưu tiên thiết bị được phục vụ ít.
8	HYBRID_BALANCED	Kết hợp hàng đợi, SINR, loại thiết bị, tính công bằng và rủi ro từ jammer.
9	HIGH_QUEUE_PRIORITY	Ưu tiên áp lực hàng đợi cao.

Executor thực hiện ánh xạ:

$$\phi_{\text{exec}} : (\mathbf{z}_t, s_t) \mapsto \mathbf{a}_t. \quad (4.4)$$

Executor là rule-based, không phải mạng học. Nó dùng thông tin môi trường như vị trí UAV/IoT, hàng đợi, năng lượng, loại thiết bị, primary busy, jammer và điểm SINR để chọn hành động nguyên thủy. Đây là ưu điểm về tri thức miền nhưng cũng là một giới hạn cần nêu rõ.

4.4. Hierarchical DDQN

Hierarchical DDQN giữ cấu trúc DDQN nhưng đầu ra là $z_t^u \in \mathcal{Z}$. Trạng thái đầu vào là kết hợp giữa trạng thái toàn cục và quan sát cục bộ. Action mask được áp dụng trước epsilon-greedy để tránh chọn hành động mức cao không hợp lệ hoặc bị vô hiệu hóa. Phương pháp này kiểm tra giả thuyết: nút thắt chính của Flat DDQN là giao diện hành động, không chỉ là kiến trúc mạng.

4.5. QMIX-Hierarchical

QMIX-Hierarchical là phương pháp MaDRL chính. Mỗi UAV là một tác tử, nhận quan sát cục bộ o_t^u và chọn hành động mức cao z_t^u . Mạng agent chia sẻ tham số ước lượng:

$$Q_u(o_t^u, z_t^u; \theta). \quad (4.5)$$

Mixer nhận các giá trị agent đã chọn và trạng thái toàn cục:

$$Q_{\text{tot}}(s_t, \mathbf{z}_t) = f_{\text{mix}}(Q_1, \dots, Q_U, s_t; \psi). \quad (4.6)$$

QMIX áp đặt ràng buộc đơn điệu:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_u} \geq 0, \quad \forall u. \quad (4.7)$$

Hình 4.2 mô tả cấu trúc huấn luyện và thực thi.




Figure 4.2: QMIX-Hierarchical. Trong huấn luyện, mixer sử dụng trạng thái toàn cục và phần thưởng chung để học Q_{tot} . Trong đánh giá, mỗi UAV chọn hành động mức cao từ quan sát cục bộ, sau đó executor chuyển sang hành động nguyên thủy.

4.6. Huấn luyện và thực thi

QMIX được huấn luyện tập trung: replay buffer lưu trajectory chung, mixer dùng trạng thái toàn cục, và phần thưởng là phần thưởng mạng. Chọn hành động mức cao mang tính cục bộ: mỗi UAV dùng quan sát của mình và agent id để tính Q-value trên 10 hành động. Quá trình thực thi nguyên thủy không hoàn toàn phi tập trung vì executor vẫn dùng thông tin môi trường để

ánh xạ hành động mức cao. Vì vậy, báo cáo dùng cách diễn đạt: *decentralized high-level action selection with a rule-based executor*.

Mục tiêu TD của QMIX:

$$y_t = r_t + \gamma(1 - d_t)Q_{\text{tot}}^-(s_{t+1}, \mathbf{z}_{t+1}^*), \quad (4.8)$$

và hàm mất mát:

$$\mathcal{L} = \frac{\sum_{b,t} M_{b,t} (Q_{\text{tot}}(s_{b,t}, \mathbf{z}_{b,t}) - y_{b,t})^2}{\sum_{b,t} M_{b,t}}, \quad (4.9)$$

trong đó $M_{b,t}$ là mask cho bước hợp lệ trong batch episode.

4.7. Pseudocode tóm tắt

Algorithm 1 Huấn luyện QMIX-Hierarchical

Require: Môi trường UAV-IoT phân cấp, agent network, mixer, replay buffer.

Ensure: Tham số agent network và mixer sau huấn luyện.

```

1: for mỗi episode do
2:   Reset môi trường và tạo trajectory rỗng.
3:   for mỗi frame do
4:     for mỗi UAV  $u$  do
5:       Tính  $Q_u(o_t^u, \cdot)$ , áp dụng action mask và chọn  $z_t^u$ .
6:     end for
7:     Executor ánh xạ  $\mathbf{z}_t$  thành  $\mathbf{a}_t$ ; môi trường trả về  $r_t$ .
8:     Lưu observation, state, action, reward, mask và next state vào trajectory.
9:   end for
10:  Cập nhật agent network và mixer bằng (4.9) nếu replay đủ lớn.
11: end for

```

4.8. Tóm tắt phương pháp

Flat DDQN kiểm tra giới hạn của điều khiển nguyên thủy. Hierarchical DDQN chứng minh rằng giảm hành động từ 864 xuống 10 làm bài toán khả học hơn. QMIX-Hierarchical là phương pháp MaDRL cuối cùng vì kết hợp trừu tượng hóa hành động với phân rã giá trị hợp tác giữa UAV. Các giới hạn gồm executor rule-based, backscatter abstraction và tính công bằng chưa được giải quyết hoàn toàn.

Chapter 5: Thực nghiệm, kết quả và thảo luận

5.1. Thiết lập thực nghiệm

Các kết quả trong chương này được lấy từ artifact Phase 3 đã có; không huấn luyện lại mô hình và không thay đổi tham số mô phỏng. Benchmark chính là Scenario 4: 2 UAV, 15 IoT dị thể, 1 jammer di động, frame length 10 và episode length 200.

Table 5.1: Thiết lập mô phỏng chính được dùng trong báo cáo.

Thành phần	Giá trị / mô tả
Số UAV	2
Số thiết bị IoT	15 thiết bị dị thể Type 1/2/3
Jammer	1 thiết bị gây nhiễu di động, bám UAV gần nhất
Độ dài frame / episode	10 / 200
Giao diện Flat DDQN	864 hành động nguyên thủy
Giao diện phân cấp	10 hành động mức cao
QMIX observation/state	Quan sát cục bộ 97 chiều, Trạng thái toàn cục 70 chiều
Kết quả thống kê	Flat DDQN và Hierarchical DDQN là single-run; QMIX base là 3 seed

Table 5.2: Các chỉ số đánh giá chính. Dấu $\uparrow$ nghĩa là càng cao càng tốt; dấu $\downarrow$ nghĩa là càng thấp càng tốt.

Chỉ số	Mục tiêu	Ý nghĩa
Throughput/frame	$\uparrow$	Số gói truyền thành công trung bình trên mỗi frame.
Packet drop	$\downarrow$	Tỷ lệ gói bị rơi do hàng đợi hoặc truyền không kịp.
Jamming failure	$\downarrow$	Tỷ lệ thất bại truyền được quy cho tác động jammer.
Fairness	$\uparrow$	Chỉ số công bằng Jain trên lượng phục vụ giữa các IoT.
Energy efficiency	$\uparrow$	Lượng dữ liệu thành công trên chi phí năng lượng.

Các phương pháp so sánh gồm Random, HTT-only, Backscatter-only, Greedy SINR, Greedy nearest, Flat DDQN, Hierarchical DDQN, QMIX-Hierarchical và các đánh giá thành phần công bằng. Các bảng trong phần này đã được rút gọn so với artifact gốc để tránh bảng quá rộng; các chỉ số phụ như active/backscatter success được giữ trong artifact Phase 3.

5.2. So sánh tổng thể trong Scenario 4

Bảng 5.3 và Hình 5.1 cho thấy Flat DDQN đạt throughput/frame 0.3242, gần HTT-only 0.3278 và thấp hơn đáng kể so với các phương pháp dùng hành động phân cấp. Điều này hỗ trợ nhận định rằng giao diện hành động nguyên thủy 864 hành động gây khó khăn cho baseline DDQN đã triển khai.

Table 5.3: So sánh tổng thể trong Scenario 4. Bảng chỉ giữ các chỉ số chính để dễ đọc.

Method	Thr.	Drop	Jam	Fair.	Ghi chú
Random	0.1075	0.6084	0.6232	0.3530	Baseline ngẫu nhiên.
HTT-only	0.3278	0.5823	0.4891	0.0937	Chỉ khai thác active/harvest-then-transmit.
Backscatter-only	0.8522	0.5294	0.5515	0.1719	Heuristic mạnh về throughput nhưng fairness thấp.
Greedy SINR	0.4783	0.5575	0.7806	0.2385	Ưu tiên liên kết tốt nhưng dễ lệch mục tiêu.
Greedy nearest	0.8977	0.5222	0.5463	0.1836	Gần IoT giúp throughput cao nhưng fairness thấp.
Flat DDQN	0.3242	0.5846	0.6093	0.1930	Gấp nút thắt action space 864.
Hierarchical DDQN	0.9710	0.4761	0.4403	0.4754	Chứng minh hiệu quả trừu tượng hóa hành động.
QMIX base	0.9604 ± 0.0255	0.4744 ± 0.0054	0.2056 ± 0.0744	0.5260 ± 0.0572	MaDRL cuối cùng, 3 seed.




Figure 5.1: Throughput/frame của các baseline và phương pháp học trong Scenario 4. Khoảng cách lớn giữa Flat DDQN và các phương pháp phân cấp cho thấy vai trò của trừu tượng hóa hành động.

Hierarchical DDQN đạt throughput/frame 0.9710, cho thấy việc giảm giao diện từ 864 xuống 10 hành động giúp bài toán khả học hơn. QMIX base đạt 0.9604 ± 0.0255 , thấp hơn nhẹ so với Hierarchical DDQN đơn chạy về throughput; vì vậy báo cáo không khẳng định QMIX vượt Hierarchical DDQN về thông lượng trung bình. Điểm mạnh của QMIX nằm ở ổn định đa seed và cải thiện các chỉ số phối hợp như jamming failure và fairness.




Figure 5.2: So sánh packet drop, jamming failure và fairness. QMIX base giảm jamming failure và cải thiện fairness so với kết quả Hierarchical DDQN đơn chạy trong gói artifact hiện có.

5.3. Tiến trình thuật toán

Bảng 5.4 và Hình 5.3 trình bày tiến trình từ Flat DDQN sang Hierarchical DDQN và QMIX-Hierarchical. Bước cải thiện lớn nhất là thay đổi giao diện hành động, không phải chỉ thay đổi mạng học.

Table 5.4: Tiến trình thuật toán từ hành động phẳng đến hành động phân cấp và QMIX.

Method	Dim	Thr.	Drop	Jam	Fair.	Diễn giải
Flat DDQN	864	0.3242	0.5846	0.6093	0.1930	Action space lớn làm học kém hiệu quả.
Flat DDQN + tuning	864	0.1203	0.6073	0.5557	0.1374	Tuning chưa giải quyết nút thắt giao diện hành động.
Hierarchical DDQN	10	0.9710	0.4761	0.4403	0.4754	Trừu tượng hóa hành động là bước cải thiện chính.
QMIX-Hierarchical	10	0.9604	0.4744	0.2056	0.5260	Giữ throughput cao và cải thiện jamming/fairness.




Figure 5.3: Tiến trình kết quả: Flat DDQN cho thấy nút thắt không gian hành động; Hierarchical DDQN chứng minh hiệu quả trừu tượng hóa hành động; QMIX thêm phối hợp đa tác tử.

Flat DDQN thấp vì môi trường chỉ cung cấp reward sau khi hành động nguyên thủy được kiểm tra qua vùng phủ, chế độ, năng lượng, hàng đợi và jammer. Trong 864 tổ hợp, nhiều hành động không hợp lệ hoặc ít giá trị trong trạng thái hiện tại. Điều này làm exploration lãng, replay buffer chứa nhiều transition kém thông tin và mạng Q khó phân biệt hành động thực sự hữu ích.

Hierarchical DDQN tăng mạnh vì 10 hành động mức cao đã mã hóa tri thức miền: phục vụ IoT gần nhất có hàng đợi, chọn SINR tốt, ưu tiên Type 2/3 cho backscatter, ưu tiên Type 1 cho active, tránh jammer và cân bằng IoT bị phục vụ ít. Agent vì vậy học trên lựa chọn chiến lược thay vì tổ hợp nguyên thủy rời rạc quá lớn.

5.4. Ổn định đa seed của QMIX

Bảng 5.5 báo cáo QMIX base trên seed 42, 43 và 44. Kết quả trung bình đạt throughput/frame 0.9604 ± 0.0255 , drop 0.4744 ± 0.0054 , jamming failure 0.2056 ± 0.0744 và fairness 0.5260 ± 0.0572 .

Table 5.5: Kết quả QMIX base theo seed và thống kê mean/std.

Run	Thr.	Drop	Jam	Fair.	Fallback
seed 42	0.9945	0.4670	0.2988	0.5981	0.0103
seed 43	0.9332	0.4796	0.2012	0.5217	0.0665
seed 44	0.9537	0.4766	0.1167	0.4581	0.0018
mean	0.9604	0.4744	0.2056	0.5260	0.0262
std	0.0255	0.0054	0.0744	0.0572	0.0287




Figure 5.4: Mean/std của QMIX base trên ba seed. Throughput ổn định hơn so với các chỉ số phối hợp như jamming failure và fairness.

Số seed là ba nên kết luận thống kê cần thận trọng. Trong phạm vi này, QMIX base duy trì throughput cao và có jamming failure thấp hơn Hierarchical DDQN single-run. Điều này phù hợp với mục tiêu chọn QMIX như phương pháp MaDRL chính: không chỉ tăng throughput, mà còn cải thiện phối hợp chống nhiễu và fairness.

5.5. Thử nghiệm đánh giá thành phần (ablation study) về tính công bằng

Bảng 5.6 và Hình 5.5 cho thấy các biến thể fairness. Biến thể fair_w2 cải thiện throughput và jam nhưng giảm fairness trung bình xuống 0.5111 ± 0.1478 . Biến thể fair_w3 làm giảm throughput và không cải thiện fairness. Do đó, tăng trọng số fairness trong executor không tự động tạo trade-off tốt hơn.

Table 5.6: Ablation công bằng. QMIX base được giữ làm thiết lập cuối cùng vì trade-off tổng thể tốt nhất trong các biến thể đã kiểm tra.

Variant	Thr.	Drop	Jam	Fair.	Diễn giải
QMIX base	0.9604 ± 0.0255	0.4744 ± 0.0054	0.2056 ± 0.0744	0.5260 ± 0.0572	Trade-off tổng thể tốt; thiết lập cuối cùng.
fair_w2	0.9883 ± 0.0350	0.4771 ± 0.0180	0.1601 ± 0.0501	0.5111 ± 0.1478	Tăng throughput/jam nhưng giảm fairness trung bình.
fair_w3	0.8877 ± 0.0094	0.4938 ± 0.0113	0.3123 ± 0.0711	0.4933 ± 0.1880	Trọng số fairness quá mạnh làm giảm hiệu năng.
no_balance	0.8439 ± 0.0473	0.4926 ± 0.0065	0.3352 ± 0.0598	0.4767 ± 0.0401	Tắt hành động cân bằng làm xấu cả throughput/fairness/jam.




Figure 5.5: Đánh đổi throughput–fairness trong các biến thể. fair_w2 có throughput và jamming tốt hơn nhưng fairness trung bình thấp hơn QMIX base.




Figure 5.6: Thử nghiệm đánh giá thành phần về tính công bằng theo nhóm chỉ số. Vô hiệu hóa hành động cân bằng làm giảm throughput/fairness và tăng jamming so với QMIX base.

Biến thể `no_balance` đạt throughput 0.8439 ± 0.0473 , fairness 0.4767 ± 0.0401 và jam 0.3352 ± 0.0598 , đều kém hơn QMIX base. Điều này ủng hộ vai trò của `BALANCE_UNDESERVED_IOT` như một thành phần hỗ trợ phối hợp công bằng, nhưng không có nghĩa fairness đã được giải quyết hoàn toàn.

5.6. Thảo luận

Kết quả hỗ trợ ba điểm chính. Thứ nhất, Flat DDQN gặp khó với giao diện hành động 864 chiều. Thứ hai, trừu tượng hóa hành động 10 mức cao là bước cải thiện quyết định. Thứ ba, QMIX-Hierarchical cung cấp cấu trúc học hợp tác phù hợp hơn cho nhiều UAV, đặc biệt ở các chỉ số jamming/fairness.

QMIX không cao hơn Hierarchical DDQN về throughput trung bình vì Hierarchical DDQN single-run đã tận dụng rất tốt executor rule-based. Tuy nhiên, QMIX bổ sung cơ chế phối hợp nhiều agent thông qua mixer, dùng trạng thái toàn cục khi huấn luyện và phần thưởng chung. Điều này làm cho lựa chọn QMIX hợp lý hơn nếu mục tiêu nghiên cứu là MaDRL cho nhiều UAV, thay vì chỉ tối đa throughput trong một lần chạy.

Các giới hạn phải được giữ rõ: kết quả dựa trên mô phỏng với 2 UAV, 15 IoT và 1 jammer; backscatter là trừu tượng mức hệ thống; executor là rule-based và dùng thông tin môi trường; một số baseline là single-run trong khi QMIX có ba seed; fairness còn ở mức trung bình; chưa có xác thực phần cứng.

5.7. Kết luận

Báo cáo đã trình bày bài toán điều khiển UAV-IoT dưới jammer di động với truyền thông backscatter-inspired/RF-powered ở mức hệ thống. Kết quả cho thấy Flat DDQN không đủ mạnh trong Scenario 4 do không gian hành động nguyên thủy lớn. Giao diện hành động phân cấp giảm số hành động trực tiếp từ 864 xuống 10 và giúp DDQN học chính sách hiệu quả hơn.

Trên cơ sở đó, QMIX-Hierarchical được chọn làm phương pháp MaDRL cuối cùng nhờ khả năng phối hợp nhiều UAV với quan sát cục bộ, phần thưởng chung, action masking và mixer dùng trạng thái toàn cục. Kết luận này cần được hiểu trong phạm vi mô phỏng hiện tại: QMIX-Hierarchical không được khẳng định vượt Hierarchical DDQN về throughput trung bình, nhưng có bằng chứng tốt hơn về ổn định đa seed và cải thiện trade-off jamming/fairness. Fairness vẫn còn ở mức trung bình và cần nghiên cứu tiếp.

5.8. Hướng phát triển

Các hướng phát triển tiếp theo gồm:

- Mở rộng quy mô với nhiều UAV, nhiều IoT và nhiều jammer hơn;
- Kiểm tra jammer thông minh hơn, thích nghi theo chính sách UAV hoặc có chiến lược gây nhiễu học được;
- Cải thiện mô hình vật lý backscatter, bao gồm liên kết RF-source-IoT-UAV và điều kiện phản cứng thực tế;
- Thay executor rule-based bằng executor học được hoặc chính sách phân cấp end-to-end;
- Thiết kế mục tiêu tính công bằng mạnh hơn, ví dụ định hình phần thưởng theo chênh lệch phục vụ của từng IoT hoặc học tăng cường có ràng buộc;
- Chạy thêm seed, kiểm định thống kê và thử nghiệm đánh giá thành phần rộng hơn;
- Đánh giá trên môi trường thực nghiệm hoặc hardware-in-the-loop.

Tài liệu tham khảo

- [1] Shimin Gong, Yutong Xie, Jing Xu, Dusit Niyato, and Ying-Chang Liang. Deep reinforcement learning for backscatter-aided data offloading in mobile edge computing. *arXiv preprint arXiv:2001.10183*, 2020.
- [2] Nguyen Van Huynh, Dinh Thai Hoang, Diep N. Nguyen, Eryk Dutkiewicz, Dusit Niyato, and Ping Wang. Reinforcement learning approach for RF-powered cognitive radio network with ambient backscatter. *arXiv preprint arXiv:1808.07601*, 2018.
- [3] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518 (7540):529–533, 2015. doi: 10.1038/nature14236.
- [4] Mohammad Mozaffari, Walid Saad, Mehdi Bennis, and Merouane Debbah. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems. *IEEE Communications Surveys & Tutorials*, 21(3):2334–2360, 2019. doi: 10.1109/COMST.2019.2902862.
- [5] Tabish Rashid, Mikayel Samvelyan, Christian Schroeder, Gregory Farquhar, Jakob Foerster, and Shimon Whiteson. QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 4295–4304. PMLR, 2018.
- [6] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.
- [7] Richard S. Sutton, Doina Precup, and Satinder Singh. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112 (1–2):181–211, 1999. doi: 10.1016/S0004-3702(99)00052-1.
- [8] The Anh Tran, Nguyen Cong Luong, Dusit Niyato, Ying-Chang Liang, and Dong In Kim. Deep reinforcement learning for time scheduling in RF-powered backscatter cognitive radio networks. *arXiv preprint arXiv:1810.04520*, 2018.
- [9] Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, 2016.

- [10] Wenyuan Xu, Wade Trappe, Yanyong Zhang, and Timothy Wood. The feasibility of launching and detecting jamming attacks in wireless networks. In *Proceedings of the 6th ACM International Symposium on Mobile Ad Hoc Networking and Computing*, pages 46–57. ACM, 2005. doi: 10.1145/1062689.1062697.