

Học tăng cường đa tác tử cho mạng UAV-IoT hỗ trợ chống gây nhiễu với truyền thông backscatter cảm hứng RF-powered

Bản nháp xem trước: Chương I–V

Sinh viên thực hiện: **TODO: Họ và tên sinh viên**

Mã số sinh viên: **TODO: MSSV**

Giảng viên hướng dẫn: **TODO: Họ và tên giảng viên**

Trường/Viện: **TODO: Tên trường**

Khoa/Bộ môn: **TODO: Tên khoa/bộ môn**

Ngày 30 tháng 5 năm 2026

Mục lục

1	Giới thiệu	5
1.1	Bối cảnh nghiên cứu	5
1.2	Vấn đề gây nhiễu trong mạng UAV-IoT	5
1.3	Động lực sử dụng học tăng cường đa tác tử	6
1.4	Mục tiêu nghiên cứu	6
1.5	Phạm vi nghiên cứu	7
1.6	Đóng góp chính	7
1.7	Cấu trúc báo cáo	8
2	Cơ sở lý thuyết và nghiên cứu liên quan	9
2.1	Mạng UAV-IoT	9
2.2	Gây nhiễu và chống nhiễu trong mạng không dây	9
2.3	Truyền thông RF-powered và backscatter-inspired	10
2.4	Mô hình quyết định Markov và học tăng cường	10
2.5	DQN và Double DQN	10
2.6	Học tăng cường phân cấp và trừu tượng hóa hành động	11
2.7	Học tăng cường đa tác tử	11
2.8	QMIX	12
2.9	Tổng quan các nghiên cứu liên quan	12
3	Mô hình hệ thống và phát biểu bài toán	13
3.1	Tổng quan mô hình mạng	13
3.2	Các thực thể trong hệ thống	13
3.2.1	UAV	13
3.2.2	Thiết bị IoT	13
3.2.3	Jammer di động và nguồn RF	14
3.3	Mô hình kênh, SINR và gây nhiễu	14
3.4	Xác suất truyền thành công và gây nhiễu thất bại	15
3.5	Mô hình năng lượng và chế độ truyền thông	15
3.6	Trạng thái, quan sát và hành động	15
3.7	Hàm thưởng và mục tiêu tối ưu	16
3.8	Các chỉ số đánh giá	16
3.9	Phát biểu bài toán	17
4	Phương pháp đề xuất	18
4.1	Tổng quan phương pháp	18
4.2	Flat DDQN như đường cơ sở	18
4.3	Trừu tượng hóa hành động phân cấp	18
4.4	Hierarchical DDQN	19

4.5	QMIX-Hierarchical	19
4.6	Huấn luyện tập trung và chọn hành động mức cao	20
4.7	Mục tiêu huấn luyện QMIX	20
4.8	Pseudocode huấn luyện	21
4.9	Lý do chọn QMIX-Hierarchical	21
5	Thiết lập thực nghiệm, kết quả và thảo luận	23
5.1	Thiết lập thực nghiệm	23
5.2	So sánh tổng thể trong Scenario 4	23
5.3	Tiến trình thuật toán: từ Flat DDQN đến QMIX-Hierarchical	24
5.4	Ổn định đa seed của QMIX	25
5.5	Ablation công bằng và BALANCE_UNDERSERVED_IOT	26
5.6	Thảo luận	27
5.7	Kết luận và hướng phát triển tạm thời	28

Danh sách hình vẽ

5.1	So sánh throughput/frame giữa baseline, Flat DDQN, Hierarchical DDQN và QMIX base.	24
5.2	So sánh drop rate, jamming failure và fairness giữa các phương pháp chính.	24
5.3	Tiến trình từ Flat DDQN sang Hierarchical DDQN và QMIX-Hierarchical.	25
5.4	Mean/std của các chỉ số chính cho QMIX base trên ba seed.	26
5.5	Đánh đổi giữa throughput và fairness trong các biến thể ablation.	27
5.6	So sánh các chỉ số chính trong ablation công bằng.	27

Danh sách bảng

4.1	Không gian hành động mức cao trong bộ thực thi phân cấp.	19
5.1	Kịch bản mô phỏng và các chỉ số đánh giá được sử dụng trong gói kết quả.	23
5.2	So sánh tổng thể trong Scenario 4.	23
5.3	Tiến trình thuật toán và vai trò của trừu tượng hóa hành động.	25
5.4	Kết quả QMIX base theo seed và thống kê mean/std.	25
5.5	Ablation công bằng và hành động BALANCE_UNDESERVED_IOT. . .	26

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Sự phát triển của Internet vạn vật (Internet of Things, IoT) làm gia tăng nhu cầu thu thập dữ liệu từ số lượng lớn thiết bị phân tán trong không gian. Trong nhiều bối cảnh, các thiết bị IoT được triển khai tại khu vực khó tiếp cận, thiếu hạ tầng truyền thông cố định, hoặc có điều kiện năng lượng hạn chế. Khi đó, việc sử dụng thiết bị bay không người lái (Unmanned Aerial Vehicle, UAV) như một nút thu thập dữ liệu, trạm chuyển tiếp, hoặc nền tảng phủ sóng tạm thời là một hướng tiếp cận linh hoạt cho mạng IoT [7].

UAV có khả năng di chuyển đến gần vùng có nhu cầu truyền dữ liệu, thay đổi vị trí phục vụ theo trạng thái mạng, và hỗ trợ mở rộng vùng phủ khi hạ tầng mặt đất không đủ đáp ứng. Đối với mạng IoT năng lượng thấp, UAV còn có thể đóng vai trò điều phối truyền thông theo thời gian, theo vị trí, và theo trạng thái hàng đợi của từng thiết bị. Nhờ tính linh hoạt này, mạng UAV-IoT phù hợp với các ứng dụng như giám sát môi trường, nông nghiệp thông minh, tìm kiếm cứu nạn, giám sát hạ tầng, và thu thập dữ liệu trong khu vực sau thiên tai.

Tuy nhiên, UAV-IoT không chỉ là bài toán mở rộng vùng phủ. Khi các thiết bị IoT có năng lượng hạn chế, chính sách phục vụ cần cân nhắc đồng thời giữa thông lượng, độ tin cậy, chi phí năng lượng, trạng thái hàng đợi, và tính công bằng giữa các thiết bị. Trong đề tài này, truyền thông backscatter cảm hứng RF-powered được xem như một cơ chế trừu tượng ở mức hệ thống cho phép thiết bị IoT năng lượng thấp lựa chọn giữa thu hoạch năng lượng, phản xạ/backscatter, và truyền chủ động. Cách mô hình hóa này không nhằm khẳng định một mô hình vật lý ambient backscatter hoàn chỉnh, mà nhằm biểu diễn các đánh đổi truyền thông có liên quan đến năng lượng trong môi trường điều khiển học tăng cường.

1.2 Vấn đề gây nhiễu trong mạng UAV-IoT

Mạng không dây dễ chịu ảnh hưởng bởi gây nhiễu vô tuyến. Trong tấn công gây nhiễu, một nguồn phát không mong muốn làm tăng mức nhiễu tại bộ thu, làm suy giảm tỉ số tín hiệu trên nhiễu và can nhiễu (Signal-to-Interference-plus-Noise Ratio, SINR), từ đó làm tăng xác suất truyền thất bại. Đối với UAV-IoT, vấn đề này trở nên nghiêm trọng hơn vì liên kết UAV-IoT phụ thuộc mạnh vào vị trí, khoảng cách, vùng phủ, và trạng thái di động của UAV.

Gây nhiễu di động là một trường hợp đặc biệt khó xử lý. Nếu bộ gây nhiễu có khả năng di chuyển hoặc bám theo UAV, vùng rủi ro nhiễu không cố định theo thời gian. Một chính sách chỉ dựa trên quy tắc tĩnh có thể phục vụ tốt trong một thời điểm nhưng trở nên kém hiệu quả khi jammer thay đổi vị trí. Trong bối cảnh đó, UAV phải vừa chọn hướng di chuyển, vừa

chọn thiết bị IoT cần phục vụ, vừa chọn chế độ truyền thông phù hợp, đồng thời tránh các vùng có nguy cơ nhiễu cao.

Tác động của gây nhiễu không chỉ thể hiện qua giảm thông lượng. Khi truyền thất bại kéo dài, hàng đợi tại thiết bị IoT tăng lên, gói tin có thể bị rơi do vượt quá dung lượng hàng đợi, và một số thiết bị có thể bị bỏ phục vụ trong thời gian dài. Do đó, chính sách chống nhiễu cần được đánh giá trên nhiều tiêu chí, bao gồm thông lượng trên mỗi frame, tỷ lệ rơi gói, tỷ lệ thất bại do nhiễu, hiệu quả năng lượng, và công bằng phục vụ giữa các thiết bị.

1.3 Động lực sử dụng học tăng cường đa tác tử

Trong môi trường UAV-IoT có jammer di động, bài toán điều khiển khó được giải hiệu quả bằng một quy tắc tối ưu tĩnh. Trạng thái mạng thay đổi theo thời gian do di chuyển của UAV, di chuyển của jammer, sinh gói ngẫu nhiên tại IoT, biến động trạng thái kênh sơ cấp, và thay đổi năng lượng/hàng đợi của thiết bị. Không gian quyết định cũng mang tính tổ hợp: mỗi UAV cần quyết định hướng di chuyển, mục tiêu IoT, và chế độ truyền thông.

Học tăng cường (Reinforcement Learning, RL) phù hợp với loại bài toán này vì tác tử có thể học chính sách thông qua tương tác với môi trường, sử dụng tín hiệu thưởng để cân bằng nhiều mục tiêu như thông lượng, chống nhiễu, năng lượng, và công bằng [5]. Các phương pháp học sâu như Deep Q-Network (DQN) và Double DQN (DDQN) cho phép xấp xỉ hàm giá trị trong không gian trạng thái lớn [3, 9].

Tuy vậy, khi có nhiều UAV cùng hoạt động, bài toán không còn là điều khiển đơn tác tử đơn giản. Mỗi UAV có quan sát cục bộ và hành động riêng, nhưng hiệu quả toàn mạng phụ thuộc vào phối hợp giữa các UAV. Ví dụ, hai UAV có thể cùng chọn phục vụ một vùng dễ truyền và bỏ qua các IoT khó phục vụ hơn; hoặc một UAV có thể di chuyển vào vùng nhiễu khiến hiệu quả chung giảm. Vì vậy, học tăng cường đa tác tử (Multi-Agent Reinforcement Learning, MaDRL) là hướng phù hợp hơn cho điều khiển nhiều UAV trong môi trường hợp tác. Trong đề tài này, QMIX được chọn làm nguyên mẫu MaDRL chính vì nó phù hợp với bài toán hợp tác có hành động rời rạc, phần thưởng chung, quan sát cục bộ, và trạng thái toàn cục dùng trong huấn luyện [4].

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hướng tiếp cận MaDRL cho mạng UAV-IoT có gây nhiễu di động và truyền thông backscatter cảm hứng RF-powered. Các mục tiêu cụ thể gồm:

- mô hình hóa môi trường phục vụ UAV-IoT trong điều kiện có jammer di động, hàng đợi IoT, năng lượng thiết bị, và các chế độ truyền thông khác nhau;
- sử dụng một trườ tượng backscatter/RF-powered ở mức hệ thống để biểu diễn các lựa chọn harvest, backscatter, active transmit và idle cho thiết bị IoT năng lượng thấp;
- so sánh đường cơ sở Flat DDQN, Hierarchical DDQN, và QMIX-Hierarchical trong cùng kịch bản đánh giá đã triển khai;
- cải thiện thông lượng và khả năng chống nhiễu, đồng thời xem xét công bằng phục vụ và các ràng buộc liên quan đến năng lượng;

- đánh giá vai trò của trù tượng hóa hành động phân cấp và cơ chế cân bằng thiết bị chưa được phục vụ đầy đủ.

1.5 Phạm vi nghiên cứu

Báo cáo này sử dụng cấu hình Scenario 4 đã được triển khai và đánh giá trong dự án làm thiết lập thực nghiệm cuối cùng. Cụ thể, cấu hình được báo cáo gồm 2 UAV, 15 thiết bị IoT, 1 jammer di động, độ dài frame bằng 10, và độ dài episode bằng 200 bước. Trong thiết lập này, không gian hành động nguyên thủy của bộ điều khiển phẳng có kích thước 864, trong khi giao diện hành động phân cấp chỉ gồm 10 hành động mức cao. Đối với QMIX-Hierarchical, kích thước quan sát cục bộ của mỗi UAV là 97 và kích thước trạng thái toàn cục là 70.

Các tham số trên phản ánh đúng thiết lập đã triển khai và đánh giá. Những bảng tham số từng được đề xuất trong giai đoạn lập kế hoạch, nếu khác với cấu hình này, chỉ được xem là tài liệu tham khảo nội bộ chứ không phải thiết lập báo cáo cuối cùng. Báo cáo không thực hiện huấn luyện lại mô hình và không thay đổi tham số mô phỏng.

Phạm vi nghiên cứu có một số giới hạn. Thứ nhất, kết quả dựa trên mô phỏng, chưa bao gồm triển khai phần cứng thực tế. Thứ hai, mô hình backscatter được sử dụng như một trù tượng ở mức hệ thống, chưa phải mô hình vật lý ambient backscatter đầy đủ. Thứ ba, bộ thực thi hành động phân cấp là thành phần dựa trên quy tắc và sử dụng thông tin môi trường để ánh xạ hành động mức cao sang hành động nguyên thủy. Các giới hạn này cần được nêu rõ khi diễn giải kết quả.

1.6 Đóng góp chính

Các đóng góp chính của đề tài được trình bày một cách thận trọng như sau:

- Xây dựng bài toán phục vụ UAV-IoT dưới tác động của jammer di động như một bài toán điều khiển học tăng cường, trong đó UAV cần phối hợp giữa di chuyển, chọn thiết bị IoT, và chọn chế độ truyền thông.
- Thiết kế và sử dụng một giao diện hành động phân cấp giúp giảm không gian hành động trực tiếp của bộ học từ 864 hành động nguyên thủy xuống 10 hành động mức cao trong Scenario 4 đã đánh giá.
- Phát triển và đánh giá phương pháp QMIX-Hierarchical, trong đó mỗi UAV chọn hành động mức cao từ quan sát cục bộ, còn mạng trộn QMIX sử dụng trạng thái toàn cục trong huấn luyện để học giá trị hành động chung.
- Đánh giá các tiêu chí thông lượng, hành vi gây nhiễu, công bằng, hiệu quả năng lượng, và ảnh hưởng của thành phần cân bằng thiết bị chưa được phục vụ đầy đủ dựa trên các kết quả thực nghiệm Phase 3 hiện có.

Các đóng góp này không nên được diễn giải là QMIX luôn vượt trội hơn mọi biến thể phân cấp về mọi chỉ số. Đặc biệt, kết quả hiện có cho thấy QMIX-Hierarchical được chọn làm phương pháp MaDRL cuối cùng nhờ tính ổn định đa seed và cải thiện các chỉ số liên quan đến gây nhiễu/công bằng, chứ không phải vì nó có thông lượng trung bình cao hơn Hierarchical DDQN trong mọi trường hợp.

1.7 Cấu trúc báo cáo

Báo cáo dự kiến được tổ chức thành năm chương:

- **Chương 1 – Giới thiệu:** trình bày bối cảnh, động lực, mục tiêu, phạm vi, và đóng góp của nghiên cứu.
- **Chương 2 – Cơ sở lý thuyết và nghiên cứu liên quan:** tổng quan về UAV-IoT, chống gây nhiễu, truyền thông backscatter/RF-powered, học tăng cường, DDQN, trừu tượng hóa hành động, MaDRL và QMIX.
- **Chương 3 – Mô hình hệ thống và phát biểu bài toán:** mô tả thực thể mạng, mô hình kênh, mô hình năng lượng, mô hình gây nhiễu, trạng thái, hành động, phần thưởng, và mục tiêu tối ưu.
- **Chương 4 – Phương pháp đề xuất:** trình bày Flat DDQN như đường cơ sở, giao diện hành động phân cấp, và QMIX-Hierarchical như phương pháp MaDRL chính.
- **Chương 5 – Thực nghiệm, kết quả, kết luận và hướng phát triển:** trình bày thiết lập thực nghiệm, so sánh phương pháp, phân tích kết quả, hạn chế, kết luận và hướng nghiên cứu tiếp theo.

Chương 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Mạng UAV-IoT

Mạng UAV-IoT là hệ thống trong đó UAV hỗ trợ các thiết bị IoT thông qua thu thập dữ liệu, mở rộng vùng phủ, chuyển tiếp thông tin, hoặc cung cấp kết nối tạm thời. So với hạ tầng cố định, UAV có lợi thế về tính linh hoạt không gian: UAV có thể di chuyển đến gần cụm thiết bị cần phục vụ, thay đổi vùng phủ theo thời gian, và hỗ trợ truyền thông tại những khu vực hạ tầng mặt đất không ổn định hoặc không tồn tại [7].

Trong bài toán thu thập dữ liệu IoT, UAV thường phải giải đồng thời nhiều quyết định. Thứ nhất, UAV cần chọn quỹ đạo hoặc hướng di chuyển để duy trì vùng phủ tốt. Thứ hai, UAV cần chọn thiết bị IoT nào được phục vụ tại từng thời điểm. Thứ ba, UAV cần cân nhắc trạng thái hàng đợi và năng lượng của thiết bị để tránh tình trạng một số thiết bị bị phục vụ quá ít. Các yếu tố này làm cho bài toán lập lịch phục vụ trong UAV-IoT trở thành bài toán điều khiển động thay vì bài toán chọn điểm đơn lẻ.

Những thách thức chính của UAV-IoT gồm biến thiên kênh do di chuyển, năng lượng UAV hữu hạn, năng lượng IoT hạn chế, nhiễu vô tuyến, khả năng va chạm hoặc trùng vùng phục vụ giữa nhiều UAV, và yêu cầu công bằng giữa các thiết bị. Khi nhiều UAV cùng hoạt động, chính sách điều khiển còn phải xét đến phối hợp đa tác tử để tránh các hành vi cục bộ kém hiệu quả, chẳng hạn nhiều UAV cùng chọn thiết bị để phục vụ trong khi bỏ qua thiết bị có hàng đợi lớn.

2.2 Gây nhiễu và chống nhiễu trong mạng không dây

Gây nhiễu là hành vi phát tín hiệu can nhiễu nhằm làm suy giảm chất lượng liên kết không dây. Về mặt truyền thông, gây nhiễu làm tăng công suất nhiễu tại bộ thu, làm giảm SINR và tăng xác suất truyền thất bại. Trong các mạng IoT năng lượng thấp, hậu quả của gây nhiễu có thể nghiêm trọng vì thiết bị khó tăng công suất phát hoặc truyền lại nhiều lần.

Trong mô hình có jammer di động, vị trí nguồn gây nhiễu thay đổi theo thời gian. Điều này làm cho vùng nguy hiểm do nhiễu không cố định, khiến chính sách chống nhiễu phải thích nghi với trạng thái hiện tại. Một UAV có thể cải thiện liên kết đến IoT bằng cách di chuyển gần thiết bị hơn, nhưng cũng có thể đi vào vùng nhiễu mạnh hơn. Ngược lại, tránh jammer có thể làm giảm rủi ro truyền thất bại nhưng làm tăng khoảng cách đến IoT cần phục vụ. Do đó, chống nhiễu trong UAV-IoT là bài toán đánh đổi giữa di chuyển, chất lượng kênh, thông lượng và công bằng.

Các phương pháp chống nhiễu truyền thống có thể dựa trên chọn kênh, điều chỉnh công

suất, né vùng nhiễu, hoặc lập lịch truyền thông. Tuy nhiên, khi môi trường có hàng đợi ngẫu nhiên, thiết bị di thể, năng lượng hạn chế và nhiều UAV, các quy tắc cố định thường khó bao quát toàn bộ trạng thái hệ thống. Đây là lý do các phương pháp học thích nghi, đặc biệt là RL và MaDRL, được xem xét cho bài toán này [6].

2.3 Truyền thông RF-powered và backscatter-inspired

RF-powered communication là hướng tiếp cận trong đó thiết bị năng lượng thấp tận dụng năng lượng vô tuyến sẵn có hoặc được cung cấp từ nguồn RF để hỗ trợ hoạt động truyền thông. Ambient backscatter là một cơ chế trong đó thiết bị không cần tạo sóng mang riêng với công suất lớn, mà điều chế thông tin bằng cách phản xạ tín hiệu RF môi trường [2]. Cách tiếp cận này hấp dẫn cho IoT vì có thể giảm nhu cầu năng lượng so với truyền chủ động.

Ở mức trực giác, một thiết bị IoT có thể rơi vào một trong các hành vi: thu hoạch năng lượng khi kênh sơ cấp bận, phản xạ/backscatter khi có tín hiệu RF phù hợp, truyền chủ động khi có đủ năng lượng và điều kiện kênh cho phép, hoặc tạm thời không truyền. Các hành vi này tạo ra bài toán lựa chọn chế độ truyền thông phụ thuộc vào trạng thái năng lượng, hàng đợi, kênh, và nhiễu.

Trong dự án này, backscatter được mô hình hóa như một trừu tượng ở mức hệ thống. Bộ mô phỏng sử dụng trạng thái kênh sơ cấp bận, hệ số công suất backscatter hiệu dụng, loại thiết bị IoT, hàng đợi, và điều kiện vùng phủ để quyết định khả năng truyền backscatter. Cách mô hình hóa này đủ để nghiên cứu điều khiển chính sách ở mức mạng, nhưng không nên được mô tả như một mô hình vật lý ambient backscatter đầy đủ.

2.4 Mô hình quyết định Markov và học tăng cường

Học tăng cường thường mô hình hóa bài toán điều khiển tuần tự bằng tiến trình quyết định Markov (Markov Decision Process, MDP). Một MDP gồm trạng thái s_t , hành động a_t , phần thưởng r_t , xác suất chuyển trạng thái, và hệ số chiết khấu γ . Mục tiêu của tác tử là học một chính sách $\pi(a|s)$ sao cho tổng phần thưởng kỳ vọng theo thời gian được tối đa hóa [5].

Trong môi trường UAV-IoT, trạng thái có thể bao gồm vị trí UAV, vị trí jammer, trạng thái kênh sơ cấp, hàng đợi IoT, năng lượng thiết bị và vùng phủ. Hành động có thể gồm di chuyển, chọn thiết bị phục vụ và chọn chế độ truyền thông. Phần thưởng được thiết kế để phản ánh mục tiêu mạng như truyền thành công, giảm rơi gói, giảm thất bại do nhiễu, tiết kiệm năng lượng và tăng công bằng.

RL phù hợp với bài toán này vì nó không yêu cầu biết trước một mô hình tối ưu đóng dạng đơn giản cho mọi trạng thái. Thay vào đó, chính sách được học thông qua tương tác, trong đó tác tử quan sát hậu quả của hành động qua phần thưởng và trạng thái kế tiếp. Tuy nhiên, khi không gian trạng thái và hành động lớn, cần sử dụng xấp xỉ hàm bằng mạng nơ-ron sâu.

2.5 DQN và Double DQN

Q-learning học hàm giá trị hành động $Q(s, a)$, biểu diễn lợi ích kỳ vọng khi thực hiện hành động a tại trạng thái s và sau đó tiếp tục theo chính sách tối ưu. DQN mở rộng Q-learning bằng cách dùng mạng nơ-ron sâu để xấp xỉ hàm Q , kết hợp bộ nhớ kinh nghiệm và mạng mục tiêu để ổn định huấn luyện [3].

Double DQN được đề xuất để giảm thiên lệch đánh giá quá cao trong DQN. Ý tưởng chính là tách việc chọn hành động tốt nhất và việc đánh giá giá trị của hành động đó bằng hai mạng khác nhau: mạng online chọn hành động, còn mạng target đánh giá giá trị [9]. Cơ chế này thường giúp ổn định học giá trị trong các bài toán có nhiều hành động rời rạc.

Trong dự án này, DDQN được dùng theo hai vai trò. Flat DDQN là đường cơ sở học trực tiếp trên không gian hành động nguyên thủy gồm di chuyển, chọn IoT và chọn chế độ truyền thông. Hierarchical DDQN giữ cùng ý tưởng DDQN nhưng thay đầu ra hành động bằng 10 hành động mức cao. Kết quả Phase 3 cho thấy DDQN không đủ hiệu quả khi dùng giao diện phẳng lớn, nhưng trở nên hữu ích khi kết hợp với trừu tượng hóa hành động phân cấp.

2.6 Học tăng cường phân cấp và trừu tượng hóa hành động

Một khó khăn lớn trong RL là không gian hành động lớn hoặc có cấu trúc tổ hợp. Khi mỗi hành động là tổ hợp của nhiều quyết định con, số lượng hành động nguyên thủy có thể tăng nhanh theo số thiết bị, chế độ truyền và lệnh di chuyển. Trong Scenario 4 của dự án, hành động phẳng có kích thước:

$$|\mathcal{A}_{\text{flat}}| = 9(N + 1)6 = 864,$$

với $N = 15$ thiết bị IoT. Không gian này chứa nhiều hành động không hợp lệ hoặc kém hữu ích trong từng trạng thái cụ thể, làm cho việc học trực tiếp trở nên khó khăn.

Học tăng cường phân cấp và trừu tượng hóa hành động giải quyết vấn đề này bằng cách cho tác tử chọn quyết định ở mức cao hơn. Sau đó, một chính sách con hoặc bộ thực thi chuyển quyết định mức cao thành hành động nguyên thủy. Trong dự án này, không gian hành động trực tiếp của tác tử được giảm từ 864 xuống 10 hành động mức cao. Các hành động này biểu diễn những chiến lược có ý nghĩa miền bài toán, chẳng hạn phục vụ IoT gần nhất có hàng đợi, phục vụ theo SINR tốt nhất, ưu tiên backscatter cho thiết bị Type 2/3, ưu tiên active cho Type 1, tránh jammer, hoặc cân bằng thiết bị chưa được phục vụ đầy đủ.

Điểm cần nêu rõ là bộ thực thi phân cấp hiện tại là rule-based, không phải một chính sách con được học end-to-end. Bộ thực thi sử dụng thông tin môi trường để chọn mục tiêu, chế độ truyền và hành động nguyên thủy tương ứng. Điều này làm tăng tính học được của bài toán, nhưng cũng có nghĩa là phương pháp kết hợp học tăng cường với tri thức miền dưới dạng quy tắc.

2.7 Học tăng cường đa tác tử

Học tăng cường đa tác tử nghiên cứu các bài toán trong đó nhiều tác tử cùng tương tác với môi trường. Trong mạng nhiều UAV, mỗi UAV có quan sát riêng và hành động riêng, nhưng kết quả toàn mạng phụ thuộc vào hành động chung. Nếu mỗi UAV học độc lập, môi trường mà một UAV quan sát có thể trở nên không dùng vì các UAV khác cũng thay đổi chính sách. Đây là một khó khăn đặc trưng của MaDRL.

Trong bài toán hợp tác, tất cả tác tử có thể chia sẻ cùng một mục tiêu, chẳng hạn tối đa hóa thông lượng toàn mạng và giảm gây nhiễu. Một hướng phổ biến là centralized training with decentralized execution (CTDE): trong huấn luyện, thuật toán có thể dùng thông tin toàn cục hoặc phần thưởng chung; trong thực thi, mỗi tác tử chỉ dùng quan sát cục bộ để chọn hành động.

Đối với dự án này, cần diễn đạt CTDE một cách cẩn trọng. QMIX-Hierarchical cho phép mỗi UAV chọn hành động mức cao dựa trên quan sát cục bộ và định danh tác tử, trong khi

mạng trộn sử dụng trạng thái toàn cục khi huấn luyện. Tuy nhiên, sau khi chọn hành động mức cao, bộ thực thi rule-based ánh xạ hành động đó sang hành động nguyên thủy bằng thông tin môi trường. Vì vậy, cách diễn đạt an toàn là: phương pháp có lựa chọn hành động mức cao theo hướng phi tập trung, kết hợp với bộ thực thi phân cấp có tri thức miền.

2.8 QMIX

QMIX là một phương pháp MaDRL cho bài toán hợp tác với hành động rời rạc [4]. Mỗi tác tử có một mạng giá trị hành động riêng để ước lượng $Q_u(o_t^u, a_t^u)$ từ quan sát cục bộ. Sau đó, một mạng trộn sử dụng trạng thái toàn cục để kết hợp các giá trị riêng lẻ thành giá trị hành động chung Q_{tot} .

Đặc điểm quan trọng của QMIX là ràng buộc đơn điệu:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_u} \geq 0.$$

Ràng buộc này cho phép hành động tối ưu chung tương thích với việc chọn hành động tối ưu cục bộ của từng tác tử. Trong thực thi, mỗi UAV có thể chọn hành động có giá trị cao nhất theo mạng của mình, trong khi quá trình huấn luyện vẫn học được mối quan hệ giữa các tác tử thông qua mạng trộn và phần thưởng chung.

QMIX phù hợp với bài toán UAV-IoT trong dự án vì sau khi trừu tượng hóa, mỗi UAV có không gian hành động rời rạc nhỏ gồm 10 hành động mức cao. Bài toán cũng mang tính hợp tác: các UAV cùng tối ưu thông lượng, giảm thất bại do nhiễu, giảm rơi gói và cải thiện công bằng. Mạng trộn QMIX cho phép khai thác trạng thái toàn cục trong huấn luyện, trong khi vẫn duy trì cấu trúc chọn hành động cục bộ ở mức cao.

2.9 Tổng quan các nghiên cứu liên quan

Các nghiên cứu về RF-powered và ambient backscatter cognitive radio đã chỉ ra tiềm năng của việc kết hợp thu hoạch năng lượng, backscatter và truyền chủ động cho thiết bị năng lượng thấp [2]. Một số hướng nghiên cứu khác xem xét học sâu và học tăng cường cho offloading hoặc lập lịch trong hệ thống backscatter/MEC [1, 8]. Các công trình này cung cấp nền tảng cho ý tưởng lựa chọn chế độ harvest/backscatter/active theo trạng thái hệ thống.

Trong lĩnh vực học tăng cường sâu, DQN và DDQN là các nền tảng quan trọng cho điều khiển hành động rời rạc [3, 9]. Tuy nhiên, các phương pháp này có thể gặp khó khăn khi không gian hành động quá lớn hoặc có cấu trúc tổ hợp. Do đó, trừu tượng hóa hành động và học phân cấp là hướng quan trọng khi áp dụng RL cho các bài toán mạng phức tạp.

Đối với hệ nhiều tác tử, QMIX và các phương pháp phân rã giá trị cho phép học chính sách hợp tác với phần thưởng chung [4]. Điều này đặc biệt liên quan đến điều khiển nhiều UAV, nơi mỗi UAV có quan sát cục bộ nhưng mục tiêu là hiệu quả toàn mạng.

Khoảng trống mà đề tài này hướng tới là sự kết hợp giữa bốn yếu tố trong cùng một thiết lập mô phỏng đã triển khai: UAV-IoT có nhiều UAV, jammer di động, truyền thông backscatter/RF-powered ở mức trừu tượng hệ thống, và điều khiển MaDRL thông qua giao diện hành động phân cấp. Cách tiếp cận này không chỉ áp dụng QMIX trực tiếp, mà còn nhấn mạnh vai trò của thiết kế giao diện hành động để làm cho bài toán học trở nên khả thi.

Chương 3

Mô hình hệ thống và phát biểu bài toán

3.1 Tổng quan mô hình mạng

Chương này mô tả mô hình hệ thống được sử dụng trong bản báo cáo xem trước. Mô hình bám theo cấu hình đã triển khai và đánh giá trong Scenario 4, thay vì dùng các bảng tham số đề xuất ở giai đoạn lập kế hoạch. Thiết lập cuối cùng gồm $U = 2$ UAV, $N = 15$ thiết bị IoT di thể, một jammer di động, độ dài frame $L = 10$, và độ dài episode $T = 200$.

Tập UAV được ký hiệu là $\mathcal{U} = \{1, \dots, U\}$, tập thiết bị IoT là $\mathcal{I} = \{1, \dots, N\}$, và tập jammer là $\mathcal{J} = \{1, \dots, J\}$. Trong mỗi bước thời gian t , UAV quan sát trạng thái mạng, chọn hành động điều khiển, và môi trường cập nhật di chuyển, truyền thông, năng lượng, hàng đợi, gây nhiễu và phần thưởng.

Ở giao diện hành động nguyên thủy, một hành động của UAV gồm ba thành phần: lệnh di chuyển, chỉ số IoT được chọn, và chế độ truyền thông. Trong các thí nghiệm phân cấp và QMIX, UAV không trực tiếp chọn hành động nguyên thủy mà chọn một hành động mức cao; bộ thực thi phân cấp ánh xạ hành động mức cao đó về hành động nguyên thủy của môi trường.

3.2 Các thực thể trong hệ thống

3.2.1 UAV

Mỗi UAV $u \in \mathcal{U}$ có vị trí hai chiều (x_t^u, y_t^u) , độ cao cố định h^u , năng lượng còn lại E_t^u , bán kính phủ R_{cov} , và vận tốc tối đa v_{max} . UAV có thể di chuyển theo một trong chín hướng rời rạc, bao gồm đứng yên, bốn hướng trục và bốn hướng chéo.

Vị trí UAV được giới hạn trong vùng mô phỏng kích thước $W \times H$. Với lệnh di chuyển $\Delta = (\Delta_x, \Delta_y)$, cập nhật vị trí có thể viết ở dạng báo cáo:

$$x_{t+1}^u = \text{clip}(x_t^u + \Delta_x v_{\text{max}}, 0, W), \quad y_{t+1}^u = \text{clip}(y_t^u + \Delta_y v_{\text{max}}, 0, H). \quad (3.1)$$

Trong triển khai, hướng chéo được chuẩn hóa khi cập nhật vị trí, còn chi phí năng lượng di chuyển được tính dựa trên chuẩn của hướng di chuyển rời rạc.

3.2.2 Thiết bị IoT

Mỗi thiết bị IoT $i \in \mathcal{I}$ có vị trí (x^i, y^i) , loại thiết bị $c_i \in \{1, 2, 3\}$, hàng đợi $q_{i,t}$, dung lượng hàng đợi Q_i^{max} , năng lượng $B_{i,t}$, và dung lượng năng lượng B_i^{max} . Scenario 4 sử dụng thiết bị

dị thể Type 1/2/3 để biểu diễn các đặc tính active, backscatter và harvest khác nhau. Gói tin đến IoT được lấy mẫu theo frame:

$$A_{i,t} \sim \text{Binomial}(L, p_i^{\text{arr}}). \quad (3.2)$$

Cập nhật hàng đợi có thể mô tả ở dạng:

$$q_{i,t+1} = \min(Q_i^{\max}, q_{i,t} - D_{i,t} + A_{i,t}), \quad (3.3)$$

trong đó $D_{i,t}$ là số gói được phục vụ thành công trong frame. Gói vượt quá $Q_i^{\max}$ được tính là gói rơi. Công thức này là mô tả mức báo cáo của logic hàng đợi trong bộ mô phỏng.

3.2.3 Jammer di động và nguồn RF

Scenario 4 sử dụng một jammer di động với cơ chế chase-nearest-UAV. Jammer tác động lên truyền thông bằng cách tạo nhiễu tại phía thu, làm giảm SINR và có thể gây thất bại truyền. Hệ thống cũng có trạng thái kênh sơ cấp bận $b_t \in \{0, 1\}$, dùng để quyết định khả năng harvest và backscatter. Trạng thái này được lấy mẫu theo xác suất bận của nguồn RF trong mô phỏng.

3.3 Mô hình kênh, SINR và gây nhiễu

Khoảng cách truyền thông được tính theo khoảng cách Euclid. Suy hao đường truyền được mô hình hóa bởi:

$$L(d) = \max(d, 1)^\alpha, \quad (3.4)$$

trong đó α là hệ số suy hao. Công suất nhận từ nguồn phát công suất P tại khoảng cách d là:

$$P_{\text{rx}}(P, d) = \frac{P}{L(d)}. \quad (3.5)$$

Nhiều do jammer j gây ra tại bộ thu r chỉ được tính khi bộ thu nằm trong bán kính ảnh hưởng của jammer:

$$I_{j,r} = \begin{cases} \frac{P_j}{\max(d_{j,r}, 1)^\alpha}, & d_{j,r}^{2D} \leq R_j, \\ 0, & \text{ngược lại.} \end{cases} \quad (3.6)$$

SINR của liên kết từ nguồn phát a đến bộ thu r được viết:

$$\Gamma_{a,r,t} = \frac{P_{\text{rx}}(P_a, d_{a,r})}{N_0 + \sum_{j \in \mathcal{J}} I_{j,r}}, \quad (3.7)$$

với N_0 là công suất nhiễu nền. Đối với truyền active, công suất phát là công suất IoT. Đối với backscatter, triển khai dùng công suất hiệu dụng dựa trên công suất nguồn RF và hệ số backscatter theo loại thiết bị; đây là trừu tượng mức hệ thống, không phải mô hình vật lý ambient backscatter đầy đủ.

3.4 Xác suất truyền thành công và gây nhiễu thất bại

Mô phỏng sử dụng xác suất thành công ngẫu nhiên dựa trên SINR và ngưỡng θ :

$$p_{\text{succ}}(\Gamma) = \begin{cases} 1, & \theta = 0 \text{ và } \Gamma > 0, \\ 0, & \theta = 0 \text{ và } \Gamma = 0, \\ \min\left(1, \frac{\Gamma}{\Gamma + \theta}\right), & \Gamma \geq \theta, \\ 0.1 \frac{\Gamma}{\theta}, & 0 \leq \Gamma < \theta. \end{cases} \quad (3.8)$$

Một thất bại truyền được xem là liên quan đến gây nhiễu nếu SINR thấp hơn ngưỡng và tổng nhiễu do jammer lớn hơn nhiễu nền. Tỷ lệ thất bại do nhiễu được sử dụng như một chỉ số đánh giá chính trong Chapter V.

3.5 Mô hình năng lượng và chế độ truyền thông

Môi trường hỗ trợ các chế độ idle, harvest, backscatter, active, relay và avoid-jammer. Báo cáo tập trung vào idle, harvest, backscatter, active và avoid-jammer vì đây là các chế độ liên quan trực tiếp đến kết quả Phase 3.

Khi thiết bị IoT harvest năng lượng, năng lượng được cập nhật:

$$B_{i,t+1} = \min(B_i^{\max}, B_{i,t} + h_i), \quad (3.9)$$

trong đó h_i là lượng năng lượng harvest theo loại thiết bị. Khi truyền active, thiết bị cần có đủ năng lượng:

$$B_{i,t} \geq c_i^{\text{act}}, \quad (3.10)$$

và năng lượng giảm sau khi truyền:

$$B_{i,t+1} = B_{i,t} - c_i^{\text{act}}. \quad (3.11)$$

UAV tiêu thụ năng lượng cho di chuyển và truyền thông. Năng lượng IoT được theo dõi trong chỉ số hiệu quả năng lượng, trong khi thành phần phạt năng lượng trực tiếp trong hàm thưởng hiện tại sử dụng năng lượng UAV.

3.6 Trạng thái, quan sát và hành động

QMIX sử dụng quan sát cục bộ của từng UAV và trạng thái toàn cục cho mạng trộn. Quan sát cục bộ o_t^u gồm vị trí/năng lượng UAV, đặc trưng jammer gần nhất, trạng thái primary busy, và đặc trưng tương đối của từng IoT. Kích thước quan sát cục bộ trong Scenario 4 là:

$$d_o = 7 + 6N = 7 + 6 \cdot 15 = 97. \quad (3.12)$$

Trạng thái toàn cục s_t gồm thông tin UAV, IoT, jammer, primary busy và bước thời gian chuẩn hóa:

$$d_s = 3U + 4N + 2J + 2 = 3 \cdot 2 + 4 \cdot 15 + 2 \cdot 1 + 2 = 70. \quad (3.13)$$

Không gian hành động phẳng có kích thước:

$$|\mathcal{A}_{\text{flat}}| = 9(N + 1)6 = 9(15 + 1)6 = 864. \quad (3.14)$$

Không gian hành động phân cấp dùng trong Hierarchical DDQN và QMIX-Hierarchical có 10 hành động mức cao:

$$|\mathcal{A}_{\text{hier}}| = 10. \quad (3.15)$$

3.7 Hàm thưởng và mục tiêu tối ưu

Các UAV chia sẻ cùng một phần thưởng môi trường. Hàm thưởng triển khai có dạng tổng có trọng số:

$$r_t = w_{\text{thr}}S_t + w_{\text{avoid}}A_t - w_{\text{drop}}D_t - w_{\text{delay}}\bar{q}_t - w_{\text{uavE}}E_t^u - w_{\text{jam}}J_t - w_{\text{col}}C_t - w_{\text{unfair}}(1 - F_t). \quad (3.16)$$

Trong đó S_t là số gói thành công, A_t là bonus tránh jammer, D_t là số gói rơi, $\bar{q}_t$ là hàng đợi trung bình, E_t^u là năng lượng UAV sử dụng, J_t là số thất bại do nhiễu, C_t là số va chạm, và F_t là chỉ số công bằng Jain.

Mục tiêu học tăng cường được viết:

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \quad (3.17)$$

Phương trình (3.17) là dạng mục tiêu RL báo cáo; DDQN và QMIX triển khai cập nhật TD tương ứng với phần thưởng chung và hệ số chiết khấu trong cấu hình.

3.8 Các chỉ số đánh giá

Thông lượng trên mỗi frame được định nghĩa:

$$\eta = \frac{\sum_{i \in \mathcal{I}} D_i}{T_{\text{ep}}}, \quad (3.18)$$

trong đó D_i là tổng số gói được phục vụ thành công của IoT i . Tỷ lệ rơi gói:

$$\rho_{\text{drop}} = \frac{\sum_i \text{Dropped}_i}{\max(\sum_i \text{Arrived}_i, 1)}. \quad (3.19)$$

Tỷ lệ thất bại do nhiễu:

$$\rho_{\text{jam}} = \frac{\text{jamming failures}}{\max(\text{transmission attempts}, 1)}. \quad (3.20)$$

Chỉ số công bằng Jain trên số gói đã phục vụ:

$$F = \frac{(\sum_i D_i)^2}{N \sum_i D_i^2 + \epsilon}. \quad (3.21)$$

Hiệu quả năng lượng:

$$\xi = \frac{\sum_i D_i}{\max(E_{\text{UAV}} + E_{\text{IoT}}, 10^{-9})}. \quad (3.22)$$

Các chỉ số này được sử dụng trong Chapter V để so sánh baseline, Flat DDQN, Hierarchical DDQN, QMIX-Hierarchical và các ablation liên quan đến công bằng.

3.9 Phát biểu bài toán

Bài toán được phát biểu như sau: trong một mạng UAV-IoT có thiết bị IoT năng lượng hạn chế, truyền thông active/backscatter/harvest ở mức trừu tượng hệ thống, và jammer di động, cần học chính sách điều khiển UAV hợp tác nhằm tối đa hóa phần thưởng kỳ vọng của toàn mạng, đồng thời tuân thủ các ràng buộc về di chuyển, vùng phủ, trạng thái kênh sơ cấp, hàng đợi, năng lượng và lựa chọn hành động hợp lệ. Chính sách được đánh giá bằng thông lượng/frame, tỷ lệ rơi gói, tỷ lệ thất bại do nhiễu, công bằng, hiệu quả năng lượng, tỷ lệ thành công active/backscatter và tỷ lệ fallback của bộ thực thi phân cấp.

Chương 4

Phương pháp đề xuất

4.1 Tổng quan phương pháp

Phương pháp trong báo cáo này được xây dựng theo tiến trình thực nghiệm đã hoàn thành: Flat DDQN được dùng như đường cơ sở học trực tiếp trên giao diện hành động nguyên thủy; Hierarchical DDQN kiểm tra tác dụng của trừu tượng hóa hành động; và QMIX-Hierarchical là phương pháp MaDRL chính dùng giao diện hành động phân cấp 10 hành động.

Điểm trung tâm của phương pháp không chỉ là thay đổi thuật toán học, mà là thiết kế lại giao diện hành động cho bộ học. Trong Scenario 4, nếu UAV trực tiếp chọn tổ hợp di chuyển, IoT mục tiêu và chế độ truyền thông, kích thước hành động là 864. Không gian này lớn, chứa nhiều tổ hợp không hợp lệ hoặc ít giá trị theo trạng thái, và gây khó khăn cho DDQN phẳng. Giao diện phân cấp giảm không gian hành động trực tiếp xuống 10 chiến lược mức cao, sau đó một executor dựa trên quy tắc ánh xạ chiến lược này về hành động nguyên thủy.

4.2 Flat DDQN như đường cơ sở

Flat DDQN dùng hành động nguyên thủy:

$$a_t^u = (m_t^u, i_t^u, c_t^u), \quad (4.1)$$

trong đó m_t^u là lệnh di chuyển, i_t^u là IoT được chọn, và c_t^u là chế độ truyền thông. DDQN học hàm giá trị hành động với mục tiêu Double-DDQN:

$$y_t = r_t + \gamma(1 - d_t)Q_{\text{target}}\left(s_{t+1}, \arg \max_{a'} Q_{\text{online}}(s_{t+1}, a')\right). \quad (4.2)$$

Flat DDQN giữ nguyên ngữ nghĩa hành động của bộ mô phỏng, do đó là baseline quan trọng để kiểm tra liệu môi trường có thể học được bằng một bộ điều khiển giá trị sâu trực tiếp hay không. Tuy nhiên, kết quả Phase 3 cho thấy baseline này gặp khó khăn với giao diện 864 hành động trong Scenario 4. Vì vậy, Flat DDQN được trình bày như đường cơ sở và công cụ chẩn đoán, không phải phương pháp cuối cùng.

4.3 Trừu tượng hóa hành động phân cấp

Giao diện phân cấp thay thế hành động phẳng bằng hành động mức cao:

$$z_t^u \in \{0, \dots, 9\}. \quad (4.3)$$

Mười hành động mức cao gồm:

Bảng 4.1: Không gian hành động mức cao trong bộ thực thi phân cấp.

ID	Hành động	Ý nghĩa chính
0	IDLE_SAFE	Nghỉ hoặc tránh truyền nếu không có cơ hội an toàn.
1	SERVE_NEAREST_QUEUE	Phục vụ IoT gần nhất có hàng đợi và nằm trong vùng phủ.
2	SERVE_BEST_SINR	Phục vụ IoT có điểm SINR tốt nhất.
3	PRIORITIZE_BACKSCATTER_TYPE23	Ưu tiên Type 2/3 và chế độ backscatter khi phù hợp.
4	PRIORITIZE_ACTIVE_TYPE1	Ưu tiên Type 1 và truyền active khi đủ điều kiện.
5	HARVEST_LOW_ENERGY	Ưu tiên thiết bị năng lượng thấp và harvest khi kênh sơ cấp bận.
6	AVOID_JAMMER	Di chuyển/tránh jammer và chỉ truyền khi an toàn.
7	BALANCE_UNDESERVED_IOT	Ưu tiên IoT được phục vụ ít hơn.
8	HYBRID_BALANCED	Kết hợp hàng đợi, SINR, loại thiết bị, công bằng, khoảng cách và rủi ro jammer.
9	HIGH_QUEUE_PRIORITY	Ưu tiên thiết bị có áp lực hàng đợi cao.

Bộ thực thi phân cấp ánh xạ:

$$\phi_{\text{exec}} : (z_t^1, \dots, z_t^U, s_t) \mapsto (a_t^1, \dots, a_t^U), \quad (4.4)$$

trong đó a_t^u là hành động nguyên thủy của UAV u . Executor này là rule-based, không phải mạng học. Nó dùng thông tin môi trường như vị trí UAV, hàng đợi/năng lượng/loại IoT, trạng thái primary busy, thông tin jammer, điểm SINR và số gói đã phục vụ để chọn mục tiêu, chế độ và fallback.

Điểm cần nhấn mạnh là chính sách học chỉ chọn hành động mức cao. Việc ánh xạ sang hành động nguyên thủy do executor thực hiện bằng tri thức miền. Điều này làm giảm độ khó học, nhưng cũng có nghĩa phương pháp không phải một chính sách end-to-end thuần túy từ quan sát đến hành động nguyên thủy.

4.4 Hierarchical DDQN

Hierarchical DDQN sử dụng cùng mạng DDQN nhưng đầu ra là 10 hành động mức cao. Trạng thái đầu vào là dạng nối giữa trạng thái toàn cục và quan sát cục bộ của UAV. Hành động được chọn bằng masked epsilon-greedy, tức là các hành động không hợp lệ hoặc bị vô hiệu hóa sẽ bị loại khỏi quá trình chọn hành động.

Hierarchical DDQN có vai trò chứng minh rằng trừu tượng hóa hành động làm bài toán Scenario 4 trở nên học được. Kết quả của nó được dùng như baseline mạnh cho hành động phân cấp, trước khi chuyển sang QMIX để học phối hợp nhiều UAV.

4.5 QMIX-Hierarchical

QMIX-Hierarchical là phương pháp MaDRL chính trong báo cáo. Mỗi UAV là một tác tử với quan sát cục bộ o_t^u . Mạng agent chia sẻ tham số ước lượng giá trị:

$$Q_u(o_t^u, z_t^u; \theta). \quad (4.5)$$

Trong triển khai, mạng agent có thể nhận thêm one-hot agent id để phân biệt UAV. Mỗi UAV chọn một hành động mức cao trong 10 hành động thông qua masked epsilon-greedy khi huấn luyện hoặc argmax hợp lệ khi đánh giá.

Mạng trộn QMIX nhận các giá trị Q_u đã chọn và trạng thái toàn cục s_t , sau đó tạo giá trị đội:

$$Q_{\text{tot}}(s_t, \mathbf{z}_t) = f_{\text{mix}}(Q_1, \dots, Q_U, s_t; \psi). \quad (4.6)$$

QMIX áp đặt ràng buộc đơn điệu:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_u} \geq 0, \quad \forall u. \quad (4.7)$$

Trong triển khai, trọng số của mixer được sinh bởi hypernetwork và lấy giá trị không âm bằng trị tuyệt đối. Điều này cho phép phối hợp giá trị hành động của từng UAV trong khi vẫn giữ cấu trúc chọn hành động cục bộ ở mức cao.

4.6 Huấn luyện tập trung và chọn hành động mức cao

QMIX được huấn luyện tập trung vì bộ nhớ replay chứa trajectory chung, mixer dùng trạng thái toàn cục, và phần thưởng là phần thưởng mạng chung. Tuy nhiên, khi chọn hành động mức cao, mỗi UAV dùng quan sát cục bộ và agent id để tạo Q-value cho 10 hành động. Cách diễn đạt chính xác là: phương pháp có chọn hành động mức cao theo hướng phi tập trung, kết hợp với executor rule-based dùng thông tin môi trường để thực thi hành động nguyên thủy.

Không nên mô tả phương pháp như fully decentralized primitive-action execution, vì executor vẫn sử dụng trạng thái môi trường để ánh xạ hành động mức cao.

4.7 Mục tiêu huấn luyện QMIX

Với batch episode, mục tiêu TD của QMIX có dạng:

$$y_t = r_t + \gamma(1 - d_t)Q_{\text{tot}}^-(s_{t+1}, \mathbf{z}_{t+1}^*), \quad (4.8)$$

trong đó $\mathbf{z}_{t+1}^*$ được chọn bằng mạng online và được đánh giá bằng mạng target. Hàm mất mát:

$$\mathcal{L} = \frac{\sum_{b,t} M_{b,t} (Q_{\text{tot}}(s_{b,t}, \mathbf{z}_{b,t}) - y_{b,t})^2}{\sum_{b,t} M_{b,t}}, \quad (4.9)$$

với $M_{b,t}$ là mask cho bước thời gian hợp lệ trong batch episode.

4.8 Pseudocode huấn luyện

Algorithm 1 Huấn luyện Hierarchical DDQN

```
1: Khởi tạo môi trường cơ sở và wrapper phân cấp 10 hành động.
2: Khởi tạo mạng DDQN online, mạng target và replay buffer.
3: for mỗi episode huấn luyện do
4:   Reset môi trường.
5:   for mỗi frame  $t$  do
6:     for mỗi UAV  $u$  do
7:       Xây dựng trạng thái từ global state và local observation.
8:       Lấy action mask mức cao.
9:       Chọn  $z_t^u$  bằng masked epsilon-greedy.
10:    end for
11:    Executor ánh xạ  $\mathbf{z}_t$  sang hành động nguyên thủy.
12:    Môi trường thực thi, trả về reward chung và trạng thái kế tiếp.
13:    Lưu transition từng UAV vào replay buffer.
14:    Cập nhật mạng DDQN nếu đủ dữ liệu.
15:  end for
16: end for
```

Algorithm 2 Huấn luyện QMIX-Hierarchical

```
1: Khởi tạo môi trường phân cấp, agent network, target agent, mixer và target mixer.
2: for mỗi episode huấn luyện do
3:   Reset môi trường và tạo trajectory rỗng.
4:   for mỗi frame  $t$  do
5:     for mỗi UAV  $u$  do
6:       Quan sát  $o_t^u$ , lấy action mask và tính  $Q_u(o_t^u, \cdot)$ .
7:       Chọn hành động mức cao  $z_t^u$  bằng masked epsilon-greedy.
8:     end for
9:     Executor chuyển  $\mathbf{z}_t$  sang hành động nguyên thủy.
10:    Môi trường cập nhật và trả về reward chung  $r_t$ .
11:    Lưu observations, global state, actions, reward, masks và next states vào trajectory.
12:  end for
13:  Đưa trajectory vào episode replay buffer.
14:  if replay buffer đủ lớn then
15:    Lấy batch episode và cập nhật agent network/mixer bằng (4.9).
16:  end if
17: end for
```

4.9 Lý do chọn QMIX-Hierarchical

QMIX-Hierarchical được chọn làm phương pháp MaDRL cuối cùng vì nó kết hợp hai yếu tố: giao diện hành động phân cấp giúp giảm độ khó học, và mạng trộn QMIX giúp học phối hợp giữa nhiều UAV thông qua giá trị đội. Kết quả Phase 3 cho thấy QMIX không nên được

diễn giải là vượt Hierarchical DDQN về thông lượng trung bình, nhưng nó có bằng chứng tốt hơn về ổn định đa seed và cải thiện hành vi liên quan đến gây nhiễu/công bằng.

Chương 5

Thiết lập thực nghiệm, kết quả và thảo luận

5.1 Thiết lập thực nghiệm

Chương này tổng hợp các kết quả Phase 3 đã được đóng gói thành bảng và hình trong thư mục publication artifacts. Không có mô hình nào được huấn luyện lại trong giai đoạn viết báo cáo này. Thiết lập chính là Scenario 4 đã triển khai: 2 UAV, 15 IoT dị thể, 1 jammer di động, frame length bằng 10 và episode length bằng 200.

Bảng 5.1: Kịch bản mô phỏng và các chỉ số đánh giá được sử dụng trong gói kết quả.

Section	Scenario / Metric	UAV count	IoT count	Jammer setting	Backscatter/active relevance	Purpose
Scenario	No-jammer calibrated	1	5	Disabled	Basic backscatter/active scheduling without jamming.	Learnability sanity check and no-jammer reference.
Scenario	Static weak jammer	2	10	One weak static jammer	Anti-jamming behavior with moderate coordination.	Intermediate transfer and robustness validation.
Scenario	Scenario 4 backscatter types	2	15	One calibrated mobile/chase jammer	Heterogeneous Type 1/2/3 devices with active, backscatter, and harvest modes.	Main heterogeneous RF-powered backscatter coordination benchmark.
Metric	Throughput/frame					Delivered packets per frame; higher is better.
Metric	Drop rate					Fraction of generated/queued packets dropped; lower is better.
Metric	Jamming failure					Transmission failures attributed to jamming; lower is better.
Metric	Fairness					Jain-style service fairness across IoT devices; higher is better.
Metric	Energy efficiency					Delivered utility per energy cost; higher is better.
Metric	Backscatter success					Successful backscatter transmission rate; higher is better.
Metric	Active success					Successful active transmission rate; higher is better.

Các phương pháp được so sánh gồm: Random, HTT-only, Backscatter-only, Greedy SINR, Greedy nearest, Flat DDQN, Hierarchical DDQN, QMIX-Hierarchical và các biến thể ablation về công bằng. Flat DDQN và Hierarchical DDQN được trình bày như các kết quả đơn chạy trong gói artifact hiện tại. QMIX base được báo cáo trên ba seed 42, 43 và 44.


5.2 So sánh tổng thể trong Scenario 4

Bảng 5.2 trình bày so sánh tổng thể trong Scenario 4. Các kết quả cho thấy Random là baseline yếu, trong khi các heuristic chuyên biệt như Backscatter-only và Greedy nearest đạt thông lượng cao. Flat DDQN chỉ đạt throughput/frame 0.3242, gần với HTT-only 0.3278, cho thấy giao diện hành động nguyên thủy 864 hành động là khó học đối với DDQN đã triển khai.


Bảng 5.2: So sánh tổng thể trong Scenario 4.

Method	Type / Category	Throughput/frame	Drop rate	Jamming failure	Fairness	Energy efficiency	Backscatter success	Active success
Random	Stochastic baseline	0.1075	0.6084	0.6232	0.3530	0.3242	0.3817	0.3640
HTT-only	Heuristic baseline	0.3278	0.5823	0.4891	0.0937	0.4029	0.0000	0.4788
Backscatter-only	Heuristic baseline	0.8522	0.5294	0.5515	0.1719	10.7016	0.4258	0.0000
Greedy SINR	Heuristic baseline	0.4783	0.5575	0.7806	0.2385	1.7265	0.1879	0.2734
Greedy nearest	Heuristic baseline	0.8977	0.5222	0.5463	0.1836	7.2350	0.4302	0.6019
Flat DDQN	Flat DRL	0.3242	0.5846	0.6093	0.1930	0.9417	0.3899	0.5231
Hierarchical DDQN	Hierarchical DRL	0.9710	0.4761	0.4403	0.4754	4.9295	0.5258	0.6817
QMIX base	MaDRL, hierarchical	0.9604 +/- 0.0255	0.4744 +/- 0.0054	0.2056 +/- 0.0744	0.5260 +/- 0.0572	5.6655 +/- 1.6622	0.7935 +/- 0.0747	0.7833 +/- 0.1068

Hierarchical DDQN đạt throughput/frame 0.9710, cao hơn rõ rệt so với Flat DDQN. Sự khác biệt này ủng hộ kết luận rằng trừu tượng hóa hành động từ 864 xuống 10 hành động mức cao là yếu tố quyết định giúp bài toán trở nên học được. QMIX base đạt throughput/frame 0.9604 ± 0.0255 , thấp hơn nhẹ so với Hierarchical DDQN đơn chạy về thông lượng, nên không nên viết rằng QMIX vượt Hierarchical DDQN về thông lượng trung bình. Điểm mạnh của QMIX là giữ thông lượng cao trong khi cải thiện chỉ số gây nhiễu và công bằng.



Hình 5.1: So sánh throughput/frame giữa baseline, Flat DDQN, Hierarchical DDQN và QMIX base.



Hình 5.2: So sánh drop rate, jamming failure và fairness giữa các phương pháp chính.

5.3 Tiến trình thuật toán: từ Flat DDQN đến QMIX-Hierarchical


Bảng 5.3 tóm tắt tiến trình thực nghiệm. Việc tinh chỉnh Flat DDQN bằng reward scaling hoặc kiến trúc dueling giúp ổn định một số khía cạnh huấn luyện nhưng không giải quyết

được nút thắt giao diện hành động. Bước chuyển quan trọng là thay giao diện phẳng bằng giao diện hành động phân cấp.

Bảng 5.3: Tiến trình thuật toán và vai trò của trừu tượng hóa hành động.

Method	Action interface	Action dimension	Multi-agent coordination	Throughput/frame	Drop rate	Jamming failure	Fairness	Interpretation
Flat DDQN	Flat movement x IoT x mode	864	Centralized-factorized DDQN	0.3242	0.5846	0.6093	0.1930	Large flat action space limits learning in heterogeneous Scenario 4.
Flat DDQN + tuning	Flat movement x IoT x mode	864	Centralized-factorized DDQN	0.1203	0.6073	0.5557	0.1374	Reward scaling and dueling stabilized loss but did not solve the action-interface bottleneck.
Hierarchical DDQN	High-level executor	10	Centralized-factorized DDQN	0.9710	0.4761	0.4403	0.4754	Action abstraction is the dominant improvement over flat DDQN.
QMIX-Hierarchical	High-level executor	10	QMIX value decomposition	0.9604	0.4744	0.2056	0.5260	QMIX preserves high throughput and improves jamming/fairness trade-off over hierarchical DDQN.

Hình 5.3 trực quan hóa câu chuyện thực nghiệm: Flat DDQN cho thấy giới hạn của điều khiển nguyên thủy; Hierarchical DDQN cho thấy hành động phân cấp làm bài toán khả học; QMIX-Hierarchical bổ sung phân rã giá trị hợp tác để cải thiện các chỉ số phối hợp.



Hình 5.3: Tiến trình từ Flat DDQN sang Hierarchical DDQN và QMIX-Hierarchical.


5.4 Ổn định đa seed của QMIX

Bảng 5.4 trình bày kết quả QMIX base trên ba seed. Thông lượng trung bình đạt 0.9604 ± 0.0255 , cho thấy độ ổn định tương đối tốt về throughput trong phạm vi ba seed. Tỷ lệ thất bại do nhiễu đạt 0.2056 ± 0.0744 , fairness đạt 0.5260 ± 0.0572 , và drop rate đạt 0.4744 ± 0.0054 .

Bảng 5.4: Kết quả QMIX base theo seed và thống kê mean/std.

Run	Throughput/frame	Reward	Drop rate	Jamming failure	Fairness	Energy efficiency	Backscatter success	Active success	Fallback rate
seed 42	0.9945	-1475.8774	0.4670	0.2988	0.5981	3.7427	0.6951	0.6411	0.0103
seed 43	0.9332	-1481.4517	0.4796	0.2012	0.5217	5.4559	0.8095	0.8101	0.0665
seed 44	0.9537	-1455.1210	0.4766	0.1167	0.4581	7.7980	0.8760	0.8987	0.0018
mean	0.9604	-1470.8167	0.4744	0.2056	0.5260	5.6655	0.7935	0.7833	0.0262
std	0.0255	11.3294	0.0054	0.0744	0.0572	1.6622	0.0747	0.1068	0.0287

Kết quả này ủng hộ việc chọn QMIX base làm thiết lập MaDRL chính. Tuy nhiên, số seed là ba nên kết luận về độ ổn định cần được viết thận trọng. Jamming và fairness có độ biến thiên tương đối lớn hơn drop rate, cho thấy phối hợp chống nhiễu và công bằng vẫn là vấn đề mở.



Hình 5.4: Mean/std của các chỉ số chính cho QMIX base trên ba seed.


5.5 Ablation công bằng và BALANCE_UNDESERVED_IOT

Bảng 5.5 trình bày ablation liên quan đến công bằng. Biến thể fair_w2 đạt throughput 0.9883 ± 0.0350 và jam 0.1601 ± 0.0501 , nhưng fairness giảm còn 0.5111 ± 0.1478 . Biến thể fair_w3 làm giảm thông lượng và không cải thiện fairness. Vì vậy, các trọng số fairness mạnh hơn không được chọn làm thiết lập cuối cùng.


Bảng 5.5: Ablation công bằng và hành động BALANCE_UNDESERVED_IOT.

Variant	Throughput/frame mean +/- std	Drop mean +/- std	Jamming failure mean +/- std	Fairness mean +/- std	Interpretation
QMIX base	0.9604 +/- 0.0255	0.4744 +/- 0.0054	0.2056 +/- 0.0744	0.5260 +/- 0.0572	Best overall trade-off; final MaDRL setting.
fair_w2	0.9883 +/- 0.0350	0.4771 +/- 0.0180	0.1601 +/- 0.0501	0.5111 +/- 0.1478	Improves throughput and jamming but reduces mean fairness.
fair_w3	0.8877 +/- 0.0094	0.4938 +/- 0.0113	0.3123 +/- 0.0711	0.4933 +/- 0.1880	Excessive fairness weighting degrades performance.
no_balance_action	0.8439 +/- 0.0473	0.4926 +/- 0.0065	0.3352 +/- 0.0598	0.4767 +/- 0.0401	Disabling balance action hurts fairness, throughput, and jamming.

Biến thể no_balance_action loại bỏ hành động BALANCE_UNDESERVED_IOT và làm giảm throughput xuống 0.8439 ± 0.0473 , giảm fairness xuống 0.4767 ± 0.0401 , đồng thời tăng jam lên 0.3352 ± 0.0598 . Điều này cho thấy hành động cân bằng thiết bị chưa được phục vụ đầy đủ có đóng góp tích cực cho hành vi phối hợp. Tuy nhiên, fairness chưa được giải quyết triệt để; chỉ số fairness của QMIX base vẫn ở mức trung bình.



Hình 5.5: Đánh đổi giữa throughput và fairness trong các biến thể ablation.



Hình 5.6: So sánh các chỉ số chính trong ablation công bằng.

5.6 Thảo luận

Kết quả hỗ trợ ba kết luận chính. Thứ nhất, giao diện hành động nguyên thủy là nút thắt đối với Flat DDQN trong Scenario 4. Với 864 hành động, Flat DDQN không cạnh tranh được với các heuristic mạnh và các phương pháp phân cấp.

Thứ hai, trừu tượng hóa hành động phân cấp là bước cải thiện quan trọng nhất. Việc giảm không gian hành động trực tiếp xuống 10 hành động mức cao giúp DDQN học được chính sách có hiệu quả cao trong thiết lập dị thể có backscatter, active, harvest và jammer di động.

Thứ ba, QMIX-Hierarchical cung cấp cấu trúc học phối hợp phù hợp hơn cho nhiều UAV. QMIX không được báo cáo là có throughput trung bình cao hơn Hierarchical DDQN, nhưng

nó cải thiện jamming failure và fairness so với Hierarchical DDQN đơn chạy, đồng thời có bằng chứng đa seed cho thiết lập base.

Cần diễn giải các kết quả với giới hạn rõ ràng. Đây là kết quả mô phỏng trong Scenario 4 với 2 UAV và 15 IoT, không phải xác nhận trên phần cứng. Backscatter là trừu tượng ở mức hệ thống. Executor phân cấp là rule-based và dùng thông tin môi trường. Flat DDQN và Hierarchical DDQN trong gói artifact hiện tại là kết quả đơn chạy, trong khi QMIX base là kết quả đa seed.

5.7 Kết luận và hướng phát triển tạm thời

Lưu ý: Mục này chỉ là placeholder cho bản xem trước. Kết luận cuối cùng và hướng phát triển chi tiết sẽ được hoàn thiện ở Phase 4.5 / Stage 5.

Tạm thời, các kết quả cho thấy trừu tượng hóa hành động phân cấp giúp làm cho bài toán UAV-IoT chống nhiễu trong Scenario 4 trở nên khả học hơn so với điều khiển phẳng. QMIX-Hierarchical là phương pháp MaDRL chính vì nó kết hợp lựa chọn hành động mức cao, phần thưởng chung, trộn trạng thái toàn cục và phối hợp nhiều UAV. Các giới hạn còn lại gồm fairness chưa được giải quyết triệt để, mô hình backscatter vẫn ở mức trừu tượng hệ thống, và cần thêm đánh giá nếu muốn mở rộng sang số lượng UAV/jammer lớn hơn hoặc triển khai thực tế.

Tài liệu tham khảo

- [1] TODO Gong and TODO. Deep reinforcement learning for backscatter-aided data offloading in mobile edge computing. *TODO*, 2020. TODO: verify authors, title, venue, pages, and DOI before final submission.
- [2] N. Van Huynh, Dinh Thai Hoang, Dusit Niyato, Ping Wang, and Dong In Kim. Optimal time scheduling in rf-powered backscatter cognitive radio networks. *IEEE Transactions on Wireless Communications*, 2018. TODO: verify exact volume, issue, pages, and DOI.
- [3] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dhharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015. doi: 10.1038/nature14236.
- [4] Tabish Rashid, Mikayel Samvelyan, Christian Schroeder, Gregory Farquhar, Jakob Foerster, and Shimon Whiteson. QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *Proceedings of the 35th International Conference on Machine Learning*, pages 4295–4304, 2018. TODO: verify proceedings volume metadata.
- [5] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.
- [6] TODO. Todo: Anti-jamming wireless communication reference. *TODO*, TODO. TODO: add a verified anti-jamming or mobile jamming reference.
- [7] TODO. Todo: Uav-assisted iot communications survey. *TODO*, TODO. TODO: add a verified UAV-IoT or UAV communications survey.
- [8] TODO Tran and TODO. Deep reinforcement learning for time scheduling in rf-powered backscatter cognitive radio networks. *TODO*, 2018. TODO: verify exact bibliographic metadata; placeholder for DDQN/time-scheduling backscatter reference.
- [9] Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2016. TODO: verify final page numbers and venue metadata.