

Học tăng cường đa tác tử cho mạng UAV-IoT hỗ trợ chống gây nhiễu với truyền thông backscatter cảm hứng RF-powered

Bản nháp xem trước: Chương I và Chương II

Sinh viên thực hiện: **TODO: Họ và tên sinh viên**

Mã số sinh viên: **TODO: MSSV**

Giảng viên hướng dẫn: **TODO: Họ và tên giảng viên**

Trường/Viện: **TODO: Tên trường**

Khoa/Bộ môn: **TODO: Tên khoa/bộ môn**

Ngày 30 tháng 5 năm 2026

Mục lục

1	Giới thiệu	2
1.1	Bối cảnh nghiên cứu	2
1.2	Vấn đề gây nhiễu trong mạng UAV-IoT	2
1.3	Động lực sử dụng học tăng cường đa tác tử	3
1.4	Mục tiêu nghiên cứu	3
1.5	Phạm vi nghiên cứu	4
1.6	Đóng góp chính	4
1.7	Cấu trúc báo cáo	5
2	Cơ sở lý thuyết và nghiên cứu liên quan	6
2.1	Mạng UAV-IoT	6
2.2	Gây nhiễu và chống nhiễu trong mạng không dây	6
2.3	Truyền thông RF-powered và backscatter-inspired	7
2.4	Mô hình quyết định Markov và học tăng cường	7
2.5	DQN và Double DQN	7
2.6	Học tăng cường phân cấp và trừu tượng hóa hành động	8
2.7	Học tăng cường đa tác tử	8
2.8	QMIX	9
2.9	Tổng quan các nghiên cứu liên quan	9

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Sự phát triển của Internet vạn vật (Internet of Things, IoT) làm gia tăng nhu cầu thu thập dữ liệu từ số lượng lớn thiết bị phân tán trong không gian. Trong nhiều bối cảnh, các thiết bị IoT được triển khai tại khu vực khó tiếp cận, thiếu hạ tầng truyền thông cố định, hoặc có điều kiện năng lượng hạn chế. Khi đó, việc sử dụng thiết bị bay không người lái (Unmanned Aerial Vehicle, UAV) như một nút thu thập dữ liệu, trạm chuyển tiếp, hoặc nền tảng phủ sóng tạm thời là một hướng tiếp cận linh hoạt cho mạng IoT [7].

UAV có khả năng di chuyển đến gần vùng có nhu cầu truyền dữ liệu, thay đổi vị trí phục vụ theo trạng thái mạng, và hỗ trợ mở rộng vùng phủ khi hạ tầng mặt đất không đủ đáp ứng. Đối với mạng IoT năng lượng thấp, UAV còn có thể đóng vai trò điều phối truyền thông theo thời gian, theo vị trí, và theo trạng thái hàng đợi của từng thiết bị. Nhờ tính linh hoạt này, mạng UAV-IoT phù hợp với các ứng dụng như giám sát môi trường, nông nghiệp thông minh, tìm kiếm cứu nạn, giám sát hạ tầng, và thu thập dữ liệu trong khu vực sau thiên tai.

Tuy nhiên, UAV-IoT không chỉ là bài toán mở rộng vùng phủ. Khi các thiết bị IoT có năng lượng hạn chế, chính sách phục vụ cần cân nhắc đồng thời giữa thông lượng, độ tin cậy, chi phí năng lượng, trạng thái hàng đợi, và tính công bằng giữa các thiết bị. Trong đề tài này, truyền thông backscatter cảm hứng RF-powered được xem như một cơ chế trừu tượng ở mức hệ thống cho phép thiết bị IoT năng lượng thấp lựa chọn giữa thu hoạch năng lượng, phản xạ/backscatter, và truyền chủ động. Cách mô hình hóa này không nhằm khẳng định một mô hình vật lý ambient backscatter hoàn chỉnh, mà nhằm biểu diễn các đánh đổi truyền thông có liên quan đến năng lượng trong môi trường điều khiển học tăng cường.

1.2 Vấn đề gây nhiễu trong mạng UAV-IoT

Mạng không dây dễ chịu ảnh hưởng bởi gây nhiễu vô tuyến. Trong tấn công gây nhiễu, một nguồn phát không mong muốn làm tăng mức nhiễu tại bộ thu, làm suy giảm tỉ số tín hiệu trên nhiễu và can nhiễu (Signal-to-Interference-plus-Noise Ratio, SINR), từ đó làm tăng xác suất truyền thất bại. Đối với UAV-IoT, vấn đề này trở nên nghiêm trọng hơn vì liên kết UAV-IoT phụ thuộc mạnh vào vị trí, khoảng cách, vùng phủ, và trạng thái di động của UAV.

Gây nhiễu di động là một trường hợp đặc biệt khó xử lý. Nếu bộ gây nhiễu có khả năng di chuyển hoặc bám theo UAV, vùng rủi ro nhiễu không cố định theo thời gian. Một chính sách chỉ dựa trên quy tắc tĩnh có thể phục vụ tốt trong một thời điểm nhưng trở nên kém hiệu quả khi jammer thay đổi vị trí. Trong bối cảnh đó, UAV phải vừa chọn hướng di chuyển, vừa

chọn thiết bị IoT cần phục vụ, vừa chọn chế độ truyền thông phù hợp, đồng thời tránh các vùng có nguy cơ nhiễu cao.

Tác động của gây nhiễu không chỉ thể hiện qua giảm thông lượng. Khi truyền thất bại kéo dài, hàng đợi tại thiết bị IoT tăng lên, gói tin có thể bị rơi do vượt quá dung lượng hàng đợi, và một số thiết bị có thể bị bỏ phục vụ trong thời gian dài. Do đó, chính sách chống nhiễu cần được đánh giá trên nhiều tiêu chí, bao gồm thông lượng trên mỗi frame, tỷ lệ rơi gói, tỷ lệ thất bại do nhiễu, hiệu quả năng lượng, và công bằng phục vụ giữa các thiết bị.

1.3 Động lực sử dụng học tăng cường đa tác tử

Trong môi trường UAV-IoT có jammer di động, bài toán điều khiển khó được giải hiệu quả bằng một quy tắc tối ưu tĩnh. Trạng thái mạng thay đổi theo thời gian do di chuyển của UAV, di chuyển của jammer, sinh gói ngẫu nhiên tại IoT, biến động trạng thái kênh sơ cấp, và thay đổi năng lượng/hàng đợi của thiết bị. Không gian quyết định cũng mang tính tổ hợp: mỗi UAV cần quyết định hướng di chuyển, mục tiêu IoT, và chế độ truyền thông.

Học tăng cường (Reinforcement Learning, RL) phù hợp với loại bài toán này vì tác tử có thể học chính sách thông qua tương tác với môi trường, sử dụng tín hiệu thưởng để cân bằng nhiều mục tiêu như thông lượng, chống nhiễu, năng lượng, và công bằng [5]. Các phương pháp học sâu như Deep Q-Network (DQN) và Double DQN (DDQN) cho phép xấp xỉ hàm giá trị trong không gian trạng thái lớn [3, 9].

Tuy vậy, khi có nhiều UAV cùng hoạt động, bài toán không còn là điều khiển đơn tác tử đơn giản. Mỗi UAV có quan sát cục bộ và hành động riêng, nhưng hiệu quả toàn mạng phụ thuộc vào phối hợp giữa các UAV. Ví dụ, hai UAV có thể cùng chọn phục vụ một vùng dễ truyền và bỏ qua các IoT khó phục vụ hơn; hoặc một UAV có thể di chuyển vào vùng nhiễu khiến hiệu quả chung giảm. Vì vậy, học tăng cường đa tác tử (Multi-Agent Reinforcement Learning, MaDRL) là hướng phù hợp hơn cho điều khiển nhiều UAV trong môi trường hợp tác. Trong đề tài này, QMIX được chọn làm nguyên mẫu MaDRL chính vì nó phù hợp với bài toán hợp tác có hành động rời rạc, phần thưởng chung, quan sát cục bộ, và trạng thái toàn cục dùng trong huấn luyện [4].

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hướng tiếp cận MaDRL cho mạng UAV-IoT có gây nhiễu di động và truyền thông backscatter cảm hứng RF-powered. Các mục tiêu cụ thể gồm:

- mô hình hóa môi trường phục vụ UAV-IoT trong điều kiện có jammer di động, hàng đợi IoT, năng lượng thiết bị, và các chế độ truyền thông khác nhau;
- sử dụng một trườ tượng backscatter/RF-powered ở mức hệ thống để biểu diễn các lựa chọn harvest, backscatter, active transmit và idle cho thiết bị IoT năng lượng thấp;
- so sánh đường cơ sở Flat DDQN, Hierarchical DDQN, và QMIX-Hierarchical trong cùng kịch bản đánh giá đã triển khai;
- cải thiện thông lượng và khả năng chống nhiễu, đồng thời xem xét công bằng phục vụ và các ràng buộc liên quan đến năng lượng;

- đánh giá vai trò của trù tượng hóa hành động phân cấp và cơ chế cân bằng thiết bị chưa được phục vụ đầy đủ.

1.5 Phạm vi nghiên cứu

Báo cáo này sử dụng cấu hình Scenario 4 đã được triển khai và đánh giá trong dự án làm thiết lập thực nghiệm cuối cùng. Cụ thể, cấu hình được báo cáo gồm 2 UAV, 15 thiết bị IoT, 1 jammer di động, độ dài frame bằng 10, và độ dài episode bằng 200 bước. Trong thiết lập này, không gian hành động nguyên thủy của bộ điều khiển phẳng có kích thước 864, trong khi giao diện hành động phân cấp chỉ gồm 10 hành động mức cao. Đối với QMIX-Hierarchical, kích thước quan sát cục bộ của mỗi UAV là 97 và kích thước trạng thái toàn cục là 70.

Các tham số trên phản ánh đúng thiết lập đã triển khai và đánh giá. Những bảng tham số từng được đề xuất trong giai đoạn lập kế hoạch, nếu khác với cấu hình này, chỉ được xem là tài liệu tham khảo nội bộ chứ không phải thiết lập báo cáo cuối cùng. Báo cáo không thực hiện huấn luyện lại mô hình và không thay đổi tham số mô phỏng.

Phạm vi nghiên cứu có một số giới hạn. Thứ nhất, kết quả dựa trên mô phỏng, chưa bao gồm triển khai phần cứng thực tế. Thứ hai, mô hình backscatter được sử dụng như một trù tượng ở mức hệ thống, chưa phải mô hình vật lý ambient backscatter đầy đủ. Thứ ba, bộ thực thi hành động phân cấp là thành phần dựa trên quy tắc và sử dụng thông tin môi trường để ánh xạ hành động mức cao sang hành động nguyên thủy. Các giới hạn này cần được nêu rõ khi diễn giải kết quả.

1.6 Đóng góp chính

Các đóng góp chính của đề tài được trình bày một cách thận trọng như sau:

- Xây dựng bài toán phục vụ UAV-IoT dưới tác động của jammer di động như một bài toán điều khiển học tăng cường, trong đó UAV cần phối hợp giữa di chuyển, chọn thiết bị IoT, và chọn chế độ truyền thông.
- Thiết kế và sử dụng một giao diện hành động phân cấp giúp giảm không gian hành động trực tiếp của bộ học từ 864 hành động nguyên thủy xuống 10 hành động mức cao trong Scenario 4 đã đánh giá.
- Phát triển và đánh giá phương pháp QMIX-Hierarchical, trong đó mỗi UAV chọn hành động mức cao từ quan sát cục bộ, còn mạng trộn QMIX sử dụng trạng thái toàn cục trong huấn luyện để học giá trị hành động chung.
- Đánh giá các tiêu chí thông lượng, hành vi gây nhiễu, công bằng, hiệu quả năng lượng, và ảnh hưởng của thành phần cân bằng thiết bị chưa được phục vụ đầy đủ dựa trên các kết quả thực nghiệm Phase 3 hiện có.

Các đóng góp này không nên được diễn giải là QMIX luôn vượt trội hơn mọi biến thể phân cấp về mọi chỉ số. Đặc biệt, kết quả hiện có cho thấy QMIX-Hierarchical được chọn làm phương pháp MaDRL cuối cùng nhờ tính ổn định đa seed và cải thiện các chỉ số liên quan đến gây nhiễu/công bằng, chứ không phải vì nó có thông lượng trung bình cao hơn Hierarchical DDQN trong mọi trường hợp.

1.7 Cấu trúc báo cáo

Báo cáo dự kiến được tổ chức thành năm chương:

- **Chương 1 – Giới thiệu:** trình bày bối cảnh, động lực, mục tiêu, phạm vi, và đóng góp của nghiên cứu.
- **Chương 2 – Cơ sở lý thuyết và nghiên cứu liên quan:** tổng quan về UAV-IoT, chống gây nhiễu, truyền thông backscatter/RF-powered, học tăng cường, DDQN, trừu tượng hóa hành động, MaDRL và QMIX.
- **Chương 3 – Mô hình hệ thống và phát biểu bài toán:** mô tả thực thể mạng, mô hình kênh, mô hình năng lượng, mô hình gây nhiễu, trạng thái, hành động, phần thưởng, và mục tiêu tối ưu.
- **Chương 4 – Phương pháp đề xuất:** trình bày Flat DDQN như đường cơ sở, giao diện hành động phân cấp, và QMIX-Hierarchical như phương pháp MaDRL chính.
- **Chương 5 – Thực nghiệm, kết quả, kết luận và hướng phát triển:** trình bày thiết lập thực nghiệm, so sánh phương pháp, phân tích kết quả, hạn chế, kết luận và hướng nghiên cứu tiếp theo.

Chương 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Mạng UAV-IoT

Mạng UAV-IoT là hệ thống trong đó UAV hỗ trợ các thiết bị IoT thông qua thu thập dữ liệu, mở rộng vùng phủ, chuyển tiếp thông tin, hoặc cung cấp kết nối tạm thời. So với hạ tầng cố định, UAV có lợi thế về tính linh hoạt không gian: UAV có thể di chuyển đến gần cụm thiết bị cần phục vụ, thay đổi vùng phủ theo thời gian, và hỗ trợ truyền thông tại những khu vực hạ tầng mặt đất không ổn định hoặc không tồn tại [7].

Trong bài toán thu thập dữ liệu IoT, UAV thường phải giải đồng thời nhiều quyết định. Thứ nhất, UAV cần chọn quỹ đạo hoặc hướng di chuyển để duy trì vùng phủ tốt. Thứ hai, UAV cần chọn thiết bị IoT nào được phục vụ tại từng thời điểm. Thứ ba, UAV cần cân nhắc trạng thái hàng đợi và năng lượng của thiết bị để tránh tình trạng một số thiết bị bị phục vụ quá ít. Các yếu tố này làm cho bài toán lập lịch phục vụ trong UAV-IoT trở thành bài toán điều khiển động thay vì bài toán chọn điểm đơn lẻ.

Những thách thức chính của UAV-IoT gồm biến thiên kênh do di chuyển, năng lượng UAV hữu hạn, năng lượng IoT hạn chế, nhiễu vô tuyến, khả năng va chạm hoặc trùng vùng phục vụ giữa nhiều UAV, và yêu cầu công bằng giữa các thiết bị. Khi nhiều UAV cùng hoạt động, chính sách điều khiển còn phải xét đến phối hợp đa tác tử để tránh các hành vi cục bộ kém hiệu quả, chẳng hạn nhiều UAV cùng chọn thiết bị để phục vụ trong khi bỏ qua thiết bị có hàng đợi lớn.

2.2 Gây nhiễu và chống nhiễu trong mạng không dây

Gây nhiễu là hành vi phát tín hiệu can nhiễu nhằm làm suy giảm chất lượng liên kết không dây. Về mặt truyền thông, gây nhiễu làm tăng công suất nhiễu tại bộ thu, làm giảm SINR và tăng xác suất truyền thất bại. Trong các mạng IoT năng lượng thấp, hậu quả của gây nhiễu có thể nghiêm trọng vì thiết bị khó tăng công suất phát hoặc truyền lại nhiều lần.

Trong mô hình có jammer di động, vị trí nguồn gây nhiễu thay đổi theo thời gian. Điều này làm cho vùng nguy hiểm do nhiễu không cố định, khiến chính sách chống nhiễu phải thích nghi với trạng thái hiện tại. Một UAV có thể cải thiện liên kết đến IoT bằng cách di chuyển gần thiết bị hơn, nhưng cũng có thể đi vào vùng nhiễu mạnh hơn. Ngược lại, tránh jammer có thể làm giảm rủi ro truyền thất bại nhưng làm tăng khoảng cách đến IoT cần phục vụ. Do đó, chống nhiễu trong UAV-IoT là bài toán đánh đổi giữa di chuyển, chất lượng kênh, thông lượng và công bằng.

Các phương pháp chống nhiễu truyền thống có thể dựa trên chọn kênh, điều chỉnh công

suất, né vùng nhiễu, hoặc lập lịch truyền thông. Tuy nhiên, khi môi trường có hàng đợi ngẫu nhiên, thiết bị di thể, năng lượng hạn chế và nhiều UAV, các quy tắc cố định thường khó bao quát toàn bộ trạng thái hệ thống. Đây là lý do các phương pháp học thích nghi, đặc biệt là RL và MaDRL, được xem xét cho bài toán này [6].

2.3 Truyền thông RF-powered và backscatter-inspired

RF-powered communication là hướng tiếp cận trong đó thiết bị năng lượng thấp tận dụng năng lượng vô tuyến sẵn có hoặc được cung cấp từ nguồn RF để hỗ trợ hoạt động truyền thông. Ambient backscatter là một cơ chế trong đó thiết bị không cần tạo sóng mang riêng với công suất lớn, mà điều chế thông tin bằng cách phản xạ tín hiệu RF môi trường [2]. Cách tiếp cận này hấp dẫn cho IoT vì có thể giảm nhu cầu năng lượng so với truyền chủ động.

Ở mức trực giác, một thiết bị IoT có thể rơi vào một trong các hành vi: thu hoạch năng lượng khi kênh sơ cấp bận, phản xạ/backscatter khi có tín hiệu RF phù hợp, truyền chủ động khi có đủ năng lượng và điều kiện kênh cho phép, hoặc tạm thời không truyền. Các hành vi này tạo ra bài toán lựa chọn chế độ truyền thông phụ thuộc vào trạng thái năng lượng, hàng đợi, kênh, và nhiễu.

Trong dự án này, backscatter được mô hình hóa như một trù tượng ở mức hệ thống. Bộ mô phỏng sử dụng trạng thái kênh sơ cấp bận, hệ số công suất backscatter hiệu dụng, loại thiết bị IoT, hàng đợi, và điều kiện vùng phủ để quyết định khả năng truyền backscatter. Cách mô hình hóa này đủ để nghiên cứu điều khiển chính sách ở mức mạng, nhưng không nên được mô tả như một mô hình vật lý ambient backscatter đầy đủ.

2.4 Mô hình quyết định Markov và học tăng cường

Học tăng cường thường mô hình hóa bài toán điều khiển tuần tự bằng tiến trình quyết định Markov (Markov Decision Process, MDP). Một MDP gồm trạng thái s_t , hành động a_t , phần thưởng r_t , xác suất chuyển trạng thái, và hệ số chiết khấu γ . Mục tiêu của tác tử là học một chính sách $\pi(a|s)$ sao cho tổng phần thưởng kỳ vọng theo thời gian được tối đa hóa [5].

Trong môi trường UAV-IoT, trạng thái có thể bao gồm vị trí UAV, vị trí jammer, trạng thái kênh sơ cấp, hàng đợi IoT, năng lượng thiết bị và vùng phủ. Hành động có thể gồm di chuyển, chọn thiết bị phục vụ và chọn chế độ truyền thông. Phần thưởng được thiết kế để phản ánh mục tiêu mạng như truyền thành công, giảm rơi gói, giảm thất bại do nhiễu, tiết kiệm năng lượng và tăng công bằng.

RL phù hợp với bài toán này vì nó không yêu cầu biết trước một mô hình tối ưu đóng dạng đơn giản cho mọi trạng thái. Thay vào đó, chính sách được học thông qua tương tác, trong đó tác tử quan sát hậu quả của hành động qua phần thưởng và trạng thái kế tiếp. Tuy nhiên, khi không gian trạng thái và hành động lớn, cần sử dụng xấp xỉ hàm bằng mạng nơ-ron sâu.

2.5 DQN và Double DQN

Q-learning học hàm giá trị hành động $Q(s, a)$, biểu diễn lợi ích kỳ vọng khi thực hiện hành động a tại trạng thái s và sau đó tiếp tục theo chính sách tối ưu. DQN mở rộng Q-learning bằng cách dùng mạng nơ-ron sâu để xấp xỉ hàm Q , kết hợp bộ nhớ kinh nghiệm và mạng mục tiêu để ổn định huấn luyện [3].

Double DQN được đề xuất để giảm thiên lệch đánh giá quá cao trong DQN. Ý tưởng chính là tách việc chọn hành động tốt nhất và việc đánh giá giá trị của hành động đó bằng hai mạng khác nhau: mạng online chọn hành động, còn mạng target đánh giá giá trị [9]. Cơ chế này thường giúp ổn định học giá trị trong các bài toán có nhiều hành động rời rạc.

Trong dự án này, DDQN được dùng theo hai vai trò. Flat DDQN là đường cơ sở học trực tiếp trên không gian hành động nguyên thủy gồm di chuyển, chọn IoT và chọn chế độ truyền thông. Hierarchical DDQN giữ cùng ý tưởng DDQN nhưng thay đầu ra hành động bằng 10 hành động mức cao. Kết quả Phase 3 cho thấy DDQN không đủ hiệu quả khi dùng giao diện phẳng lớn, nhưng trở nên hữu ích khi kết hợp với trừu tượng hóa hành động phân cấp.

2.6 Học tăng cường phân cấp và trừu tượng hóa hành động

Một khó khăn lớn trong RL là không gian hành động lớn hoặc có cấu trúc tổ hợp. Khi mỗi hành động là tổ hợp của nhiều quyết định con, số lượng hành động nguyên thủy có thể tăng nhanh theo số thiết bị, chế độ truyền và lệnh di chuyển. Trong Scenario 4 của dự án, hành động phẳng có kích thước:

$$|\mathcal{A}_{\text{flat}}| = 9(N + 1)6 = 864,$$

với $N = 15$ thiết bị IoT. Không gian này chứa nhiều hành động không hợp lệ hoặc kém hữu ích trong từng trạng thái cụ thể, làm cho việc học trực tiếp trở nên khó khăn.

Học tăng cường phân cấp và trừu tượng hóa hành động giải quyết vấn đề này bằng cách cho tác tử chọn quyết định ở mức cao hơn. Sau đó, một chính sách con hoặc bộ thực thi chuyển quyết định mức cao thành hành động nguyên thủy. Trong dự án này, không gian hành động trực tiếp của tác tử được giảm từ 864 xuống 10 hành động mức cao. Các hành động này biểu diễn những chiến lược có ý nghĩa miền bài toán, chẳng hạn phục vụ IoT gần nhất có hàng đợi, phục vụ theo SINR tốt nhất, ưu tiên backscatter cho thiết bị Type 2/3, ưu tiên active cho Type 1, tránh jammer, hoặc cân bằng thiết bị chưa được phục vụ đầy đủ.

Điểm cần nêu rõ là bộ thực thi phân cấp hiện tại là rule-based, không phải một chính sách con được học end-to-end. Bộ thực thi sử dụng thông tin môi trường để chọn mục tiêu, chế độ truyền và hành động nguyên thủy tương ứng. Điều này làm tăng tính học được của bài toán, nhưng cũng có nghĩa là phương pháp kết hợp học tăng cường với tri thức miền dưới dạng quy tắc.

2.7 Học tăng cường đa tác tử

Học tăng cường đa tác tử nghiên cứu các bài toán trong đó nhiều tác tử cùng tương tác với môi trường. Trong mạng nhiều UAV, mỗi UAV có quan sát riêng và hành động riêng, nhưng kết quả toàn mạng phụ thuộc vào hành động chung. Nếu mỗi UAV học độc lập, môi trường mà một UAV quan sát có thể trở nên không dùng vì các UAV khác cũng thay đổi chính sách. Đây là một khó khăn đặc trưng của MaDRL.

Trong bài toán hợp tác, tất cả tác tử có thể chia sẻ cùng một mục tiêu, chẳng hạn tối đa hóa thông lượng toàn mạng và giảm gây nhiễu. Một hướng phổ biến là centralized training with decentralized execution (CTDE): trong huấn luyện, thuật toán có thể dùng thông tin toàn cục hoặc phần thưởng chung; trong thực thi, mỗi tác tử chỉ dùng quan sát cục bộ để chọn hành động.

Đối với dự án này, cần diễn đạt CTDE một cách cẩn trọng. QMIX-Hierarchical cho phép mỗi UAV chọn hành động mức cao dựa trên quan sát cục bộ và định danh tác tử, trong khi

mạng trộn sử dụng trạng thái toàn cục khi huấn luyện. Tuy nhiên, sau khi chọn hành động mức cao, bộ thực thi rule-based ánh xạ hành động đó sang hành động nguyên thủy bằng thông tin môi trường. Vì vậy, cách diễn đạt an toàn là: phương pháp có lựa chọn hành động mức cao theo hướng phi tập trung, kết hợp với bộ thực thi phân cấp có tri thức miền.

2.8 QMIX

QMIX là một phương pháp MaDRL cho bài toán hợp tác với hành động rời rạc [4]. Mỗi tác tử có một mạng giá trị hành động riêng để ước lượng $Q_u(o_t^u, a_t^u)$ từ quan sát cục bộ. Sau đó, một mạng trộn sử dụng trạng thái toàn cục để kết hợp các giá trị riêng lẻ thành giá trị hành động chung Q_{tot} .

Đặc điểm quan trọng của QMIX là ràng buộc đơn điệu:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_u} \geq 0.$$

Ràng buộc này cho phép hành động tối ưu chung tương thích với việc chọn hành động tối ưu cục bộ của từng tác tử. Trong thực thi, mỗi UAV có thể chọn hành động có giá trị cao nhất theo mạng của mình, trong khi quá trình huấn luyện vẫn học được mối quan hệ giữa các tác tử thông qua mạng trộn và phần thưởng chung.

QMIX phù hợp với bài toán UAV-IoT trong dự án vì sau khi trừu tượng hóa, mỗi UAV có không gian hành động rời rạc nhỏ gồm 10 hành động mức cao. Bài toán cũng mang tính hợp tác: các UAV cùng tối ưu thông lượng, giảm thất bại do nhiễu, giảm rơi gói và cải thiện công bằng. Mạng trộn QMIX cho phép khai thác trạng thái toàn cục trong huấn luyện, trong khi vẫn duy trì cấu trúc chọn hành động cục bộ ở mức cao.

2.9 Tổng quan các nghiên cứu liên quan

Các nghiên cứu về RF-powered và ambient backscatter cognitive radio đã chỉ ra tiềm năng của việc kết hợp thu hoạch năng lượng, backscatter và truyền chủ động cho thiết bị năng lượng thấp [2]. Một số hướng nghiên cứu khác xem xét học sâu và học tăng cường cho offloading hoặc lập lịch trong hệ thống backscatter/MEC [1, 8]. Các công trình này cung cấp nền tảng cho ý tưởng lựa chọn chế độ harvest/backscatter/active theo trạng thái hệ thống.

Trong lĩnh vực học tăng cường sâu, DQN và DDQN là các nền tảng quan trọng cho điều khiển hành động rời rạc [3, 9]. Tuy nhiên, các phương pháp này có thể gặp khó khăn khi không gian hành động quá lớn hoặc có cấu trúc tổ hợp. Do đó, trừu tượng hóa hành động và học phân cấp là hướng quan trọng khi áp dụng RL cho các bài toán mạng phức tạp.

Đối với hệ nhiều tác tử, QMIX và các phương pháp phân rã giá trị cho phép học chính sách hợp tác với phần thưởng chung [4]. Điều này đặc biệt liên quan đến điều khiển nhiều UAV, nơi mỗi UAV có quan sát cục bộ nhưng mục tiêu là hiệu quả toàn mạng.

Khoảng trống mà đề tài này hướng tới là sự kết hợp giữa bốn yếu tố trong cùng một thiết lập mô phỏng đã triển khai: UAV-IoT có nhiều UAV, jammer di động, truyền thông backscatter/RF-powered ở mức trừu tượng hệ thống, và điều khiển MaDRL thông qua giao diện hành động phân cấp. Cách tiếp cận này không chỉ áp dụng QMIX trực tiếp, mà còn nhấn mạnh vai trò của thiết kế giao diện hành động để làm cho bài toán học trở nên khả thi.

Tài liệu tham khảo

- [1] TODO Gong and TODO. Deep reinforcement learning for backscatter-aided data offloading in mobile edge computing. *TODO*, 2020. TODO: verify authors, title, venue, pages, and DOI before final submission.
- [2] N. Van Huynh, Dinh Thai Hoang, Dusit Niyato, Ping Wang, and Dong In Kim. Optimal time scheduling in rf-powered backscatter cognitive radio networks. *IEEE Transactions on Wireless Communications*, 2018. TODO: verify exact volume, issue, pages, and DOI.
- [3] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dhharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015. doi: 10.1038/nature14236.
- [4] Tabish Rashid, Mikayel Samvelyan, Christian Schroeder, Gregory Farquhar, Jakob Foerster, and Shimon Whiteson. QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *Proceedings of the 35th International Conference on Machine Learning*, pages 4295–4304, 2018. TODO: verify proceedings volume metadata.
- [5] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.
- [6] TODO. Todo: Anti-jamming wireless communication reference. *TODO*, TODO. TODO: add a verified anti-jamming or mobile jamming reference.
- [7] TODO. Todo: Uav-assisted iot communications survey. *TODO*, TODO. TODO: add a verified UAV-IoT or UAV communications survey.
- [8] TODO Tran and TODO. Deep reinforcement learning for time scheduling in rf-powered backscatter cognitive radio networks. *TODO*, 2018. TODO: verify exact bibliographic metadata; placeholder for DDQN/time-scheduling backscatter reference.
- [9] Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2016. TODO: verify final page numbers and venue metadata.